

Vectores, matrices y sistemas lineales

Reinforcement Learning, segundo semestre

Ignacio Brevis

*Versión 1.0. Si encuentras algún error o tienes comentarios, escíbeme a
ignaciobrve@unisabana.edu.co.*

Resumen

Esta guía cubre qué es un **vector**, qué es una **matriz**, qué significa **multiplicar** una matriz por un vector, cómo eso permite **resolver de golpe** la ecuación de Bellman mediante una **matriz inversa**, y qué son las **normas**, que sirven para medir si un algoritmo ya ha terminado de aprender. No se supone ningún conocimiento previo, no hay símbolos de sumatorio y todas las cuentas están hechas paso a paso. Al final hay ejercicios con pistas y soluciones completas.

Índice

1. Antes de empezar	2
1.1. Por qué hace falta esto	2
1.2. Tabla de notación	2
1.3. El ejemplo que usaremos constantemente	2
2. Vectores	3
2.1. La idea	3
2.2. Ejemplos cotidianos	3
2.3. El vector de valores del gridworld	4
2.4. Las dos operaciones básicas	4
3. Matrices	4
3.1. La idea	5
3.2. La matriz del gridworld	5
3.3. Un trozo manejable	5
4. Multiplicar una matriz por un vector	6
4.1. La receta	6
4.2. Ejemplo cotidiano	6
4.3. Ejemplo en el gridworld	7
4.4. La matriz identidad	7
5. Resolver de golpe: sistemas y matriz inversa	7
5.1. De los números a los vectores	8
5.2. La inversa de una matriz 2×2	8
5.3. La ecuación de Bellman en forma matricial	9
5.4. Un ejemplo completo con dos casillas	9
6. Normas: medir el tamaño de un vector	10
6.1. Por qué hace falta	10
6.2. Las dos normas que se usan	11
6.3. Distancia entre dos vectores	11

7. Resumen	12
8. Ejercicios	12
9. Soluciones	14
Siguiente paso	16

1. Antes de empezar

1.1. Por qué hace falta esto

El mapa del gridworld descrito en la Sección 1.3 tiene **25 casillas**, y el agente necesita saber lo que valen todas para poder decidir hacia dónde ir. Podríamos escribir veinticinco ecuaciones, una por casilla. Sería correcto pero muy tedioso. Peor aún: los problemas reales de RL tienen miles o millones de estados. Hace falta una forma de escribir «los 25 valores» como si fueran un único objeto, y de operar con ellos todos a la vez.

Eso es exactamente lo que hace el álgebra lineal. Un vector es una lista; una matriz es una tabla; multiplicarlos es hacer varias sumas de golpe. Nada más.

1.2. Tabla de notación

La notación no es un obstáculo: es una abreviatura. Esta tabla está aquí para consultarla.

Símbolo	Significa
v	un vector: una lista ordenada de números
$v(s)$	el número que ocupa la posición s dentro de v
P	una matriz: una tabla de números
Pv	el vector que resulta de multiplicar la matriz por el vector
I	la matriz que no cambia nada al multiplicar
A^{-1}	la matriz que deshace lo que hace A
$\ v\ $	la «longitud» del vector
$\ v\ _{\infty}$	el mayor de sus números, en valor absoluto
γ	el factor de descuento (aquí siempre 0.9)

1.3. El ejemplo que usaremos constantemente

Usaremos un mundo de juguete muy común en RL: una cuadrícula de 5×5 casillas. Un robot se mueve por ella.

0	1	2	3	4
5	6	7	8	9
10	11	12	13	14
15	16	17	18	19
20	21	22	23	24

Las reglas son sencillas:

- Las 25 casillas se numeran del 0 al 24. Cada casilla es un **estado**.

- En cada turno el robot elige una de **5 acciones**: arriba, derecha, abajo, izquierda o quedarse quieto.
- El movimiento es **exacto**: si elige «derecha», va a la derecha, sin fallos. Si intenta salirse de la cuadrícula, choca contra la pared y se queda donde estaba.
- Después de moverse recibe una **recompensa**, que es un número:
 - -1 si choca contra una pared,
 - -1 si acaba en una casilla **naranja** (son celdas penalizadas),
 - $+1$ si acaba en la casilla **azul** (es el objetivo),
 - 0 si acaba en una casilla **blanca**.

Observación. En este ejemplo, la casilla azul no es terminal: llegar a ella no termina el episodio. Si el robot está en la casilla azul y decide quedarse, recibe nuevamente una recompensa de $+1$.

2. Vectores

La idea en una frase. Un vector es una **lista ordenada de números**. Nada más. Lo único que lo distingue de un montón de números sueltos es que las posiciones importan.

2.1. La idea

Si apunto en un papel

$$3 \quad 7 \quad 2$$

y acordamos de antemano que el primer número son las manzanas, el segundo los huevos y el tercero las botellas de leche, entonces esa lista es un vector. Se escribe entre paréntesis o corchetes y, muy a menudo, en columna:

$$v = \begin{bmatrix} 3 \\ 7 \\ 2 \end{bmatrix}.$$

Definición 2.1 (Vector). Un *vector* es una lista ordenada de números. El número de elementos que tiene se llama su *dimensión*.

El vector de arriba tiene dimensión 3. Para referirnos a un elemento concreto usamos su posición: $v(1) = 3$, $v(2) = 7$, $v(3) = 2$.

Cuidado. El orden importa. Los vectores $[3, 7, 2]$ y $[7, 3, 2]$ son *distintos*, aunque contengan los mismos números. Si el primer hueco son manzanas y el segundo huevos, cambiarlos de sitio cambia la compra. Esto distingue un vector de un simple conjunto de números.

2.2. Ejemplos cotidianos

Ejemplo 2.2 (La compra). $v = [3, 7, 2]$: tres manzanas, siete huevos, dos botellas de leche.

Ejemplo 2.3 (Un punto en el mapa). La posición de una ciudad, dada por latitud y longitud: $[40.4, -3.7]$. Dimensión 2. Éste es el ejemplo del que viene la palabra «vector»: en dos o tres dimensiones se puede dibujar como una flecha. A partir de cuatro ya no se puede dibujar, pero la aritmética sigue funcionando igual, y eso es lo único que nos importa.

2.3. El vector de valores del gridworld

Aquí está la razón de ser de todo esto. En la guía anterior calculamos el valor de una casilla. Llamemos $v(s)$ al valor de la casilla s . Como hay 25 casillas, tenemos 25 números:

$$v = \begin{bmatrix} v(0) \\ v(1) \\ v(2) \\ \vdots \\ v(24) \end{bmatrix} \quad (\text{dimensión } 25).$$

Este objeto tiene nombre en RL: es la **función de valor**. Y lo interesante es que podemos mirarlo de dos maneras que son la misma cosa:

- como una **columna de 25 números**, que es lo cómodo para calcular;
- como una **cuadrícula de 5×5** , que es lo cómodo para entender, porque cada número se ve en su casilla.

Colocar los 25 números sobre el mapa es sólo una comodidad visual: para las matemáticas sigue siendo una lista con un orden fijado (del 0 al 24, de izquierda a derecha y de arriba abajo).

Conexión con RL. Cuando en un libro de RL se lee v_π , con el subíndice π , significa «el vector de valores de *todos* los estados, cuando el agente sigue la política π ». Es un solo símbolo que representa 25 números (o un millón, según el problema). Ese es exactamente el ahorro de notación que buscábamos.

2.4. Las dos operaciones básicas

Con vectores se pueden hacer dos cosas muy sencillas.

Sumar dos vectores. Se suman posición a posición. Los dos vectores tienen que tener la misma dimensión:

$$\begin{bmatrix} 3 \\ 7 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 5 \end{bmatrix} = \begin{bmatrix} 3+1 \\ 7+0 \\ 2+5 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 7 \end{bmatrix}.$$

Multiplicar por un número. Se multiplica cada elemento:

$$2 \cdot \begin{bmatrix} 3 \\ 7 \\ 2 \end{bmatrix} = \begin{bmatrix} 6 \\ 14 \\ 4 \end{bmatrix}.$$

En este contexto, a los números sueltos se les llama **escalares**, para distinguirlos de los vectores. Es sólo una palabra: escalar significa «número normal y corriente».

Observación. Multiplicar un vector por 0.9 es exactamente lo que hace el factor de descuento γ en RL: encoge todos los valores futuros a la vez, en la misma proporción.

3. Matrices

La idea en una frase. Una matriz es una **tabla rectangular de números**. Se describe por su tamaño: tantas filas por tantas columnas.

3.1. La idea

Si un vector es una lista, una matriz es una tabla. Por ejemplo, los precios de tres productos en tres cafeterías:

	Café	Tostada	Jugo
Cafetería A	1.20	2.50	1.80
Cafetería B	1.00	3.00	2.00
Cafetería C	1.50	2.00	1.50

Si quitamos los títulos y dejamos sólo los números, tenemos una matriz:

$$A = \begin{bmatrix} 1.20 & 2.50 & 1.80 \\ 1.00 & 3.00 & 2.00 \\ 1.50 & 2.00 & 1.50 \end{bmatrix}.$$

Definición 3.1 (Matriz). Una *matriz* es una tabla rectangular de números. Su *tamaño* se escribe como «filas $\times$ columnas».

La matriz A es de tamaño 3×3 . Una matriz de 5 filas y 2 columnas es de tamaño 5×2 . El orden de la descripción es siempre el mismo: **primero filas, después columnas**.

Cuidado. Es fácil confundirse con el orden. Un truco que funciona: se lee como se escribe un texto, primero se baja por la página (filas) y luego se cruza (columnas).

3.2. La matriz del gridworld

Fijemos una política concreta: el robot ya ha aprendido algo y en cada casilla toma siempre una acción determinada. Entonces podemos construir una tabla que responda a esta pregunta:

«si estoy en la casilla s , ¿a qué casilla s' voy a parar?»

Esa tabla es la **matriz de transición** P . Tiene 25 filas (una por casilla de partida) y 25 columnas (una por casilla de llegada): en total $25 \times 25 = 625$ números.

Suena enorme, pero está casi vacía. Como el movimiento es exacto, desde cada casilla se va a **una sola** casilla concreta. Así que cada fila tiene un único 1 (en la columna de la casilla de destino) y veinticuatro 0.

Por ejemplo, si la política dice «en la casilla 22, ir hacia arriba», el robot acaba en la 17, y la fila 22 de P es:

$$\text{fila 22 : } \underbrace{0 \ 0 \ \dots \ 0}_{\text{columnas 0 a 16}} \quad \underbrace{1}_{\text{col. 17}} \quad \underbrace{0 \ \dots \ 0}_{\text{columnas 18 a 24}}$$

Observación. Leer una fila de P es leer una frase: «desde aquí, voy allí». El 1 marca el destino. Si la política fuera aleatoria en lugar de exacta, en vez de un único 1 habría varias probabilidades repartidas por la fila (por ejemplo cinco valores de 0.2) y sumarían 1. Cada fila de P es una distribución de probabilidad.

3.3. Un trozo manejable

Para hacer cuentas de verdad necesitamos algo que quepa en la página, así que nos vamos a fijar en la esquina inferior derecha del mapa: las casillas 18, 19, 23 y 24. Supongamos que la política del robot en esas cuatro casillas es:

Desde	Acción	Llega a
18	derecha	19
19	abajo	24
23	derecha	24
24	arriba	19

Ordenando las casillas como 18, 19, 23, 24, la matriz de transición de este trozo es de tamaño 4×4 :

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{array}{l} \leftarrow \text{desde 18, voy a 19} \\ \leftarrow \text{desde 19, voy a 24} \\ \leftarrow \text{desde 23, voy a 24} \\ \leftarrow \text{desde 24, voy a 19} \end{array}$$

Cada fila tiene exactamente un 1, en la columna del destino. Nótese que la tercera columna (la de la casilla 23) está entera a cero: eso significa que *nadie* llega a la casilla 23 con esta política.

4. Multiplicar una matriz por un vector

La idea en una frase. Multiplicar una matriz por un vector es hacer **varias sumas ponderadas de golpe**: una por cada fila de la matriz.

4.1. La receta

Para multiplicar una matriz A por un vector v :

1. Coge la **primera fila** de A y el vector v .
2. Multiplica el primer número de la fila por el primero de v , el segundo por el segundo, y así con todos.
3. Suma esos productos. El resultado es el **primer número** del vector respuesta.
4. Repite con la segunda fila, la tercera, etc.

El resultado es un vector nuevo, con tantos elementos como filas tenía la matriz.

Cuidado. Para que la operación tenga sentido, el **número de columnas de la matriz** debe coincidir con la **dimensión del vector**. Si no coinciden, no se puede multiplicar y punto: la operación no está definida. Una matriz 3×3 sólo puede multiplicar vectores de dimensión 3.

4.2. Ejemplo cotidiano

Volvamos a la matriz de precios de las tres cafeterías. Quiero pedir 2 cafés, 1 tostada y 3 jugos. Eso es un vector:

$$q = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}.$$

¿Cuánto me costaría el pedido en cada cafetería? Multiplicamos A por q , fila a fila:

Fila 1 (cafetería A): $2(1.20) + 1(2.50) + 3(1.80) = 2.40 + 2.50 + 5.40 = 10.30$.

Fila 2 (cafetería B): $2(1.00) + 1(3.00) + 3(2.00) = 2.00 + 3.00 + 6.00 = 11.00$.

Fila 3 (cafetería C): $2(1.50) + 1(2.00) + 3(1.50) = 3.00 + 2.00 + 4.50 = 9.50$.

Es decir,

$$Aq = \begin{bmatrix} 1.20 & 2.50 & 1.80 \\ 1.00 & 3.00 & 2.00 \\ 1.50 & 2.00 & 1.50 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 10.30 \\ 11.00 \\ 9.50 \end{bmatrix}.$$

Con una sola operación hemos respondido tres preguntas a la vez. Y aquí ya se ve la utilidad: con trescientas cafeterías, la fórmula sería idéntica.

4.3. Ejemplo en el gridworld

Ahora la parte interesante. Tomemos el trozo de cuatro casillas de la Sección 3.3 y supongamos que ya conocemos, de algún modo, sus valores:

$$v = \begin{bmatrix} -2 \\ 1 \\ 3 \\ 2 \end{bmatrix} \begin{matrix} \leftarrow v(18) \\ \leftarrow v(19) \\ \leftarrow v(23) \\ \leftarrow v(24) \end{matrix}$$

Calculemos Pv :

Fila 1: $0(-2) + 1(1) + 0(3) + 0(2) = 1$.

Fila 2: $0(-2) + 0(1) + 0(3) + 1(2) = 2$.

Fila 3: $0(-2) + 0(1) + 0(3) + 1(2) = 2$.

Fila 4: $0(-2) + 1(1) + 0(3) + 0(2) = 1$.

$$Pv = \begin{bmatrix} 1 \\ 2 \\ 2 \\ 1 \end{bmatrix}.$$

¿Qué es este vector nuevo? Miremos el primer número: vale 1, que es justamente $v(19)$, el valor de la casilla a la que va el robot desde la 18. Y el segundo vale 2, que es $v(24)$, adonde va desde la 19.

Pv es el vector que contiene, para cada casilla,
el valor de la casilla a la que se va a ir.

Toda la fuerza de la notación está aquí: los ceros y unos de P hacen automáticamente el trabajo de «ir a buscar» el valor correcto para cada casilla, las 25 a la vez.

4.4. La matriz identidad

Entre los números, el 1 es especial: multiplicar por él no cambia nada. Entre las matrices existe el equivalente, y se llama **matriz identidad**, escrita I . Tiene unos en la diagonal y ceros en todo lo demás:

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Al multiplicarla por cualquier vector, lo devuelve intacto: $Iv = v$. Merece la pena comprobarlo una vez a mano con $v = [3, 7, 2]$, porque explica por qué la diagonal está donde está.

5. Resolver de golpe: sistemas y matriz inversa

La idea en una frase. Si con números la ecuación $ax = b$ se resuelve dividiendo, con matrices la ecuación $Av = b$ se resuelve multiplicando por la **matriz inversa** A^{-1} .

5.1. De los números a los vectores

Todo el mundo sabe resolver

$$5x = 20 \quad \implies \quad x = \frac{20}{5} = 4.$$

Otra forma de decir lo mismo es que multiplicamos por el *inverso* de 5, que es $1/5$:

$$x = \frac{1}{5} \cdot 20 = 4.$$

Con matrices no existe la división, pero sí existe el inverso. La matriz A^{-1} —léase «inversa de A »— es la que **deshace** lo que hace A , en el sentido de que

$$A^{-1}A = I.$$

Es la traducción exacta de $\frac{1}{5} \cdot 5 = 1$.

Propiedad 5.1. Si $Av = b$ y A tiene inversa, entonces

$$v = A^{-1}b.$$

Cuidado. No todas las matrices tienen inversa, igual que el número 0 no tiene inverso ($1/0$ no existe). Cuando una matriz no tiene inversa, el sistema de ecuaciones o bien no tiene solución o bien tiene infinitas. Por suerte, en el caso que nos interesa la inversa siempre existe, y más abajo veremos por qué.

5.2. La inversa de una matriz 2×2

Calcular inversas grandes se deja al ordenador, pero el caso 2×2 se hace a mano con una fórmula corta. Si

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

se calcula primero un número llamado **determinante**:

$$\det = ad - bc,$$

y entonces

$$A^{-1} = \frac{1}{\det} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

La receta es: se intercambian a y d , se cambia el signo a b y a c , y se divide todo por el determinante. Si el determinante sale 0, la matriz no tiene inversa (ahí está el paralelo con la división por cero).

5.3. La ecuación de Bellman en forma matricial

Recordemos que el valor de una casilla es la recompensa inmediata más el valor descontado de la casilla siguiente. Casilla por casilla, eso se escribe:

$$v(s) = r(s) + \gamma v(\text{casilla siguiente}).$$

Pero ya sabemos escribir las tres piezas como vectores y matrices. El vector r recoge las recompensas de todas las casillas; el vector v recoge los valores; y Pv es, como acabamos de ver, el vector de valores de las casillas siguientes. Así que las 25 ecuaciones se escriben en una sola línea:

$$v = r + \gamma Pv$$

Ésta es la **ecuación de Bellman en forma matricial**, y es una de las expresiones más citadas de todo el aprendizaje por refuerzo. Lo que dice, en palabras simples, es: *el valor de cada casilla es lo que gana ahora más lo que valdrá donde acabe, con descuento*.

Lo notable es que v aparece a los dos lados. Es una ecuación, y podemos despejarla como cualquier otra:

$$v - \gamma Pv = r.$$

Sacando v como factor común (aquí es donde hace falta la identidad, porque $v - \gamma Pv$ no se puede escribir como $(1 - \gamma P)v$):

$$(I - \gamma P)v = r,$$

y por tanto

$$v = (I - \gamma P)^{-1}r$$

Conexión con RL. Esta última fórmula tiene un nombre: **solución cerrada** de la ecuación de Bellman. Dice que si conocemos el mapa (P) y las recompensas (r), podemos calcular los valores de *las 25 casillas de una vez*, sin simulaciones, sin episodios y sin aprendizaje: sólo invirtiendo una matriz.

¿Por qué entonces existe el aprendizaje por refuerzo? Por dos razones. Primero: en los problemas reales **no conocemos** P ni r , el agente tiene que descubrirlos interactuando con el entorno. Segundo: aunque los conociéramos, invertir una matriz de un millón por un millón es inviable. Los algoritmos de RL son, en el fondo, formas de aproximar esta misma solución sin llegar a calcularla nunca.

Por cierto, la inversa siempre existe aquí, y la razón es intuitiva: como $\gamma < 1$, la matriz γP «encoge» todo lo que toca, y una matriz que encoge nunca puede cancelar del todo a la identidad.

5.4. Un ejemplo completo con dos casillas

Hagamos la cuenta entera con números. Nos quedamos con dos casillas del mapa: la 22 y la 17 (la azul). La política del robot es:

Desde	Acción	Llega a	Recompensa
22	arriba	17	+1 (entra en la azul)
17	quedarse	17	+1 (sigue en la azul)

Ordenando las casillas como (22, 17), tenemos

$$P = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}, \quad r = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \gamma = 0.9.$$

Paso 1: calcular γP . Se multiplica cada número por 0.9:

$$\gamma P = \begin{bmatrix} 0 & 0.9 \\ 0 & 0.9 \end{bmatrix}.$$

Paso 2: calcular $I - \gamma P$. Se restan posición a posición:

$$I - \gamma P = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0 & 0.9 \\ 0 & 0.9 \end{bmatrix} = \begin{bmatrix} 1 & -0.9 \\ 0 & 0.1 \end{bmatrix}.$$

Paso 3: invertir. Con $a = 1$, $b = -0.9$, $c = 0$, $d = 0.1$:

$$\det = (1)(0.1) - (-0.9)(0) = 0.1,$$

$$(I - \gamma P)^{-1} = \frac{1}{0.1} \begin{bmatrix} 0.1 & 0.9 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 9 \\ 0 & 10 \end{bmatrix}.$$

Paso 4: multiplicar por r .

$$v = \begin{bmatrix} 1 & 9 \\ 0 & 10 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1(1) + 9(1) \\ 0(1) + 10(1) \end{bmatrix} = \begin{bmatrix} 10 \\ 10 \end{bmatrix}.$$

Es decir, $v(22) = 10$ y $v(17) = 10$.

Comprobación. Siempre conviene verificar sustituyendo en la ecuación original $v = r + \gamma P v$. Para la casilla 17: $1 + 0.9(10) = 1 + 9 = 10$. Correcto. Para la 22: $1 + 0.9(10) = 10$. Correcto también.

Observación. ¿Por qué valen lo mismo las dos casillas? Porque con esta política el robot gana +1 en cada turno pase lo que pase: desde la 22 gana +1 al entrar en la azul y luego +1 para siempre; desde la 17 gana +1 inmediatamente y también para siempre. Las dos situaciones son igual de buenas.

El número 10 tampoco es casual: es lo que vale una recompensa de +1 repetida eternamente con descuento 0.9. Cuanto más cerca esté γ de 1, más grande sale ese total; con $\gamma = 0.99$ saldría 100.

6. Normas: medir el tamaño de un vector

La idea en una frase. Una norma convierte un vector entero en **un solo número** que mide lo grande que es. Sirve, sobre todo, para medir **cuánto se parecen dos vectores**.

6.1. Por qué hace falta

Los algoritmos de RL no calculan la solución de golpe: la van mejorando poco a poco. Producen una primera estimación v_1 , luego v_2 , luego $v_3 \dots$. Y en algún momento hay que decidir si parar. La pregunta que hay que responder es:

«¿se parece mi estimación nueva a la anterior?»

Pero v_1 y v_2 son listas de 25 números cada una. «Parecerse» no está claro de entrada: ¿basta con que 24 de los 25 sean casi iguales? Necesitamos convertir esa comparación en un único número que podamos comparar con un umbral. Eso es una norma.

6.2. Las dos normas que se usan

Definición 6.1 (Norma euclídea). Es la longitud «de toda la vida»: se elevan al cuadrado todos los elementos, se suman y se saca la raíz:

$$\|v\| = \sqrt{v(1)^2 + v(2)^2 + \dots + v(n)^2}.$$

Ejemplo 6.2. Para $v = [3, 4]$:

$$\|v\| = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5.$$

Es el teorema de Pitágoras: si el vector fuera una flecha desde el origen, su longitud sería 5.

Definición 6.3 (Norma del máximo). Se toma el mayor de todos los elementos, ignorando los signos:

$$\|v\|_\infty = \text{el mayor de } |v(1)|, |v(2)|, \dots, |v(n)|.$$

Las barras $|\cdot|$ significan «valor absoluto», es decir, quitar el signo menos: $|-3| = 3$.

Ejemplo 6.4. Para $v = [3, -4, 1]$: los valores absolutos son 3, 4 y 1, así que $\|v\|_\infty = 4$.

Observación. En RL se usa normalmente la norma del máximo, y la razón es significativa. La norma del máximo dice «el error *en la peor* de las casillas», y eso es una garantía fuerte: si es pequeña, entonces *todas* las casillas están bien estimadas, sin excepción. La euclídea, en cambio, permite que un error enorme en una casilla quede disimulado por muchos aciertos en las demás.

6.3. Distancia entre dos vectores

Para medir cuánto se parecen dos vectores, se restan y se mide la norma del resultado:

$$\text{distancia}(v, w) = \|v - w\|.$$

Ejemplo 6.5 (Parar o seguir). Un algoritmo produce dos estimaciones consecutivas de los valores de tres casillas:

$$v_k = \begin{bmatrix} 1.0 \\ 2.0 \\ 3.0 \end{bmatrix}, \quad v_{k+1} = \begin{bmatrix} 1.1 \\ 1.9 \\ 3.2 \end{bmatrix}.$$

La diferencia es

$$v_{k+1} - v_k = \begin{bmatrix} 0.1 \\ -0.1 \\ 0.2 \end{bmatrix},$$

y su norma del máximo es $\|v_{k+1} - v_k\|_\infty = 0.2$, porque 0.2 es el mayor de 0.1, 0.1 y 0.2.

Si nuestro criterio era «parar cuando el cambio sea menor que 0.01», todavía no hemos terminado: hay que seguir iterando.

Conexión con RL. Esta comprobación es literalmente la última línea de casi todos los algoritmos de RL tabular. Se itera, se mide $\|v_{k+1} - v_k\|_\infty$, y se para cuando baja de un umbral pequeño. La norma es lo que convierte «ya casi no cambia» en un criterio preciso que un programa puede evaluar.

7. Resumen

Concepto	En una frase	En el gridworld
Vector	Lista ordenada de números	v : los 25 valores
Dimensión	Cuántos números tiene	25
Matriz	Tabla de números	P : adónde voy desde cada casilla
Tamaño	Filas $\times$ columnas	25×25
Pv	Muchas sumas ponderadas a la vez	el valor de la casilla siguiente
Identidad I	La matriz que no cambia nada	$Iv = v$
Inversa A^{-1}	La que deshace lo que hace A	permite despejar v
Bellman matricial	Valor = recompensa + futuro	$v = r + \gamma Pv$
Solución cerrada	Los 25 valores de una vez	$v = (I - \gamma P)^{-1}r$
Norma	El tamaño de un vector, en un número	$\ v\ _\infty$
Distancia	Norma de la diferencia	$\ v_{k+1} - v_k\ _\infty$

8. Ejercicios

Cada ejercicio incluye una *pista*. Las soluciones completas están en la Sección 9.

Ejercicio 1 (Vectores). Sean $u = [2, -1, 4]$ y $w = [0, 3, 1]$.

- ¿Qué dimensión tienen?
- Calcule $u + w$.
- Calcule $3u$.
- Calcule $u - w$.
- ¿Son iguales los vectores $[2, -1, 4]$ y $[-1, 2, 4]$?

Pista: todas las operaciones se hacen posición a posición. Para (d), reste elemento a elemento, respetando los signos.

Ejercicio 2 (Tamaños). Diga el tamaño de cada matriz y si la multiplicación indicada es posible.

- $A = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 5 \end{bmatrix}$, multiplicada por $v = [1, 0, 2]$.
- La misma A , multiplicada por $w = [1, 0]$.
- Una matriz 25×25 multiplicada por un vector de dimensión 25.

Pista: la regla es que el número de columnas de la matriz debe coincidir con la dimensión del vector.

Ejercicio 3 (Matriz por vector). Con la matriz de precios de las cafeterías,

$$A = \begin{bmatrix} 1.20 & 2.50 & 1.80 \\ 1.00 & 3.00 & 2.00 \\ 1.50 & 2.00 & 1.50 \end{bmatrix},$$

calcule el coste en cada cafetería de un pedido de 1 café, 2 tostadas y 0 jugos. ¿Cuál sale más barata? *Pista:* el vector del pedido es $[1, 2, 0]$. Los términos con 0 no aportan nada.

Ejercicio 4 (La identidad). Compruebe a mano que

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 7 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 7 \\ 2 \end{bmatrix},$$

haciendo las tres filas por separado. Después explique en una frase por qué los unos tienen que estar en la diagonal y no en otro sitio. *Pista:* fíjese en qué posición del vector «selecciona» el 1 de cada fila.

Ejercicio 5 (Gridworld: construir P). Nos fijamos en las cuatro casillas de la esquina superior izquierda del mapa: 0, 1, 5 y 6 (recuerde que la 6 es naranja). La política del robot es:

Desde	Acción
0	derecha
1	izquierda
5	arriba
6	arriba

- (a) Diga a qué casilla llega el robot desde cada una de las cuatro.
- (b) Escriba la matriz P de tamaño 4×4 , ordenando las casillas como 0, 1, 5, 6.
- (c) Si los valores fueran $v = [4, 2, 1, -3]$, calcule Pv .

Pista: para (a), use el mapa de la Sección 1.3 y recuerde que subir desde la fila de arriba es chocar contra la pared, y entonces el robot se queda donde está.

Ejercicio 6 (Una inversa). Sea

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}.$$

- (a) Calcule su determinante.
- (b) Calcule A^{-1} .
- (c) Compruebe que $A^{-1}A = I$ multiplicando la primera fila de A^{-1} por cada columna de A .

Pista: la fórmula es $\det = ad - bc$ y luego se intercambian a y d , se cambia el signo de b y c , y se divide por el determinante.

Ejercicio 7 (Bellman con dos casillas). Volvemos a las casillas 22 y 17, en ese orden, con $\gamma = 0.9$. Pero ahora el robot tiene una política peor: en la casilla 22 se queda quieto (recompensa 0, porque la 22 es blanca) y en la 17 también se queda quieto (recompensa +1).

- (a) Escriba P y r .
- (b) Calcule $I - \gamma P$ y su inversa.
- (c) Calcule $v = (I - \gamma P)^{-1}r$.

(d) Compare con el resultado del texto ($v = [10, 10]$) y explique la diferencia.

Pista: si el robot se queda quieto en su casilla, la fila correspondiente de P tiene el 1 en su propia columna, es decir, en la diagonal.

Ejercicio 8 (Normas). (a) Calcule $\|v\|$ y $\|v\|_\infty$ para $v = [6, -8]$.

(b) Un algoritmo pasa de $v_k = [5.0, -2.0, 0.5]$ a $v_{k+1} = [5.02, -2.01, 0.53]$. Calcule $\|v_{k+1} - v_k\|_\infty$.

(c) Si el criterio de parada es «parar cuando la norma del máximo sea menor que 0.05», ¿hay que parar?

Pista: en (b) reste primero componente a componente y después quite los signos antes de buscar el mayor.

9. Soluciones

Solución 1.

(a) Ambos tienen dimensión 3.

(b) $u + w = [2 + 0, -1 + 3, 4 + 1] = [2, 2, 5]$.

(c) $3u = [6, -3, 12]$.

(d) $u - w = [2 - 0, -1 - 3, 4 - 1] = [2, -4, 3]$.

(e) **No.** Contienen los mismos tres números, pero en distinto orden, y en un vector el orden forma parte de la identidad del objeto. Si el primer hueco fuera el valor de la casilla 0 y el segundo el de la casilla 1, intercambiarlos diría algo completamente distinto sobre el mapa.

Solución 2.

(a) A es de tamaño 2×3 (dos filas, tres columnas). El vector v tiene dimensión 3, que coincide con el número de columnas, así que **sí** se puede multiplicar. El resultado tendrá dimensión 2, una por fila.

(b) **No** se puede: A tiene 3 columnas y w tiene dimensión 2. No hay con qué emparejar el tercer número de cada fila.

(c) **Sí:** 25 columnas y dimensión 25 coinciden. El resultado tiene dimensión 25. Éste es precisamente el caso del gridworld.

Solución 3. El pedido es $q = [1, 2, 0]$.

Fila 1: $1(1.20) + 2(2.50) + 0(1.80) = 1.20 + 5.00 + 0 = 6.20$.

Fila 2: $1(1.00) + 2(3.00) + 0(2.00) = 1.00 + 6.00 + 0 = 7.00$.

Fila 3: $1(1.50) + 2(2.00) + 0(1.50) = 1.50 + 4.00 + 0 = 5.50$.

Es decir, $Aq = [6.20, 7.00, 5.50]$. La cafetería **C** es la más barata, con 5.50 euros.

Solución 4. Fila 1: $1(3) + 0(7) + 0(2) = 3$. Fila 2: $0(3) + 1(7) + 0(2) = 7$. Fila 3: $0(3) + 0(7) + 1(2) = 2$. El resultado es $[3, 7, 2]$, el vector original.

Los unos tienen que estar en la diagonal porque el 1 de la fila k es el que «selecciona» un elemento del vector, y los ceros anulan todos los demás. Para que la fila k devuelva el elemento k , el 1 tiene que estar en la columna k : es decir, en la diagonal. Si estuviera en otro sitio, la matriz reordenaría el vector en vez de dejarlo igual.

Solución 5.

- (a) Desde la 0, a la derecha está la 1. Desde la 1, a la izquierda está la 0. Desde la 5, arriba está la 0. Desde la 6, arriba está la 1. (Ninguna choca con pared en este caso.)
- (b) Con el orden 0, 1, 5, 6:

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{array}{l} \leftarrow \text{de 0 a 1} \\ \leftarrow \text{de 1 a 0} \\ \leftarrow \text{de 5 a 0} \\ \leftarrow \text{de 6 a 1} \end{array}$$

- (c) Con $v = [4, 2, 1, -3]$:

$$\text{Fila 1: } 0(4) + 1(2) + 0(1) + 0(-3) = 2.$$

$$\text{Fila 2: } 1(4) + 0(2) + 0(1) + 0(-3) = 4.$$

$$\text{Fila 3: } 1(4) + 0(2) + 0(1) + 0(-3) = 4.$$

$$\text{Fila 4: } 0(4) + 1(2) + 0(1) + 0(-3) = 2.$$

$$Pv = [2, 4, 4, 2].$$

Obsérvese que las columnas tercera y cuarta de P están enteras a cero: con esta política nadie llega nunca a las casillas 5 ni 6. Tiene sentido, porque ninguna de las cuatro acciones apunta hacia abajo. Y en Pv no aparece por ningún lado el -3 , que era el valor de la casilla naranja: como nadie entra en ella, su valor no influye en el de las demás.

Solución 6.

- (a) Con $a = 2$, $b = 1$, $c = 1$, $d = 1$: $\det = (2)(1) - (1)(1) = 2 - 1 = 1$.
- (b) Como el determinante vale 1, dividir por él no cambia nada:

$$A^{-1} = \frac{1}{1} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

- (c) Primera fila de A^{-1} , que es $[1, -1]$:

- por la primera columna de A , que es $[2, 1]$: $1(2) + (-1)(1) = 2 - 1 = 1$;
- por la segunda columna de A , que es $[1, 1]$: $1(1) + (-1)(1) = 1 - 1 = 0$.

La primera fila del producto es $[1, 0]$, que es justamente la primera fila de la identidad. Correcto.

Solución 7.

- (a) Si el robot se queda en su sitio en ambas casillas, cada fila tiene el 1 en su propia columna:

$$P = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad r = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

(La recompensa es 0 en la casilla 22 porque es blanca, y +1 en la 17 porque es azul.)

- (b)

$$\gamma P = \begin{bmatrix} 0.9 & 0 \\ 0 & 0.9 \end{bmatrix}, \quad I - \gamma P = \begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix}.$$

El determinante es $(0.1)(0.1) - (0)(0) = 0.01$, y

$$(I - \gamma P)^{-1} = \frac{1}{0.01} \begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix} = \begin{bmatrix} 10 & 0 \\ 0 & 10 \end{bmatrix}.$$

(c)

$$v = \begin{bmatrix} 10 & 0 \\ 0 & 10 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 10(0) + 0(1) \\ 0(0) + 10(1) \end{bmatrix} = \begin{bmatrix} 0 \\ 10 \end{bmatrix}.$$

Es decir, $v(22) = 0$ y $v(17) = 10$.

Comprobación en la ecuación original: para la 22, $0 + 0.9(0) = 0$. Correcto. Para la 17, $1 + 0.9(10) = 10$. Correcto.

- (d) Antes las dos casillas valían 10; ahora la 22 vale 0. La casilla 17 no ha cambiado, porque el robot hace en ella exactamente lo mismo que antes. Lo que ha cambiado es la 22: el robot ya no sube al objetivo, sino que se queda quieto en una casilla blanca para siempre, cobrando 0 eternamente.

Es la misma lección de la guía anterior, ahora en forma matricial: **el valor de una casilla no es una propiedad del mapa, sino del mapa y de la política**. El mapa es idéntico en los dos casos; sólo ha cambiado P .

Solución 8.

- (a) Euclídea: $\|v\| = \sqrt{6^2 + (-8)^2} = \sqrt{36 + 64} = \sqrt{100} = 10$. Del máximo: los valores absolutos son 6 y 8, así que $\|v\|_\infty = 8$.

Nótese que la euclídea sale mayor que la del máximo. Eso pasa siempre: la euclídea acumula todas las componentes, mientras que la del máximo sólo mira la peor.

- (b) La diferencia es

$$v_{k+1} - v_k = [5.02 - 5.0, -2.01 - (-2.0), 0.53 - 0.5] = [0.02, -0.01, 0.03].$$

Quitando los signos: 0.02, 0.01, 0.03. El mayor es 0.03, así que $\|v_{k+1} - v_k\|_\infty = 0.03$.

- (c) **Sí, hay que parar**, porque 0.03 es menor que el umbral 0.05. Ninguna de las tres casillas ha cambiado más de 0.03, así que la estimación se ha estabilizado lo suficiente según el criterio fijado.

Siguiente paso

Con esta guía y la anterior ya están cubiertos los dos pilares que sostienen el aprendizaje por refuerzo: la **probabilidad**, que sirve para hablar de lo incierto, y el **álgebra lineal**, que sirve para manejar muchos números a la vez.

Lo que viene después combina las dos cosas: la **iteración de valores**, que aplica $v \leftarrow r + \gamma P v$ una y otra vez hasta que la norma de la diferencia se hace pequeña —en vez de invertir la matriz—; la **aproximación de funciones**, necesaria cuando hay tantos estados que el vector v no cabe en la memoria; y los **métodos de gradiente**, que ajustan sus parámetros poco a poco.

Ninguna de esas ideas introduce objetos nuevos. Todas se apoyan en vectores, matrices, promedios ponderados y una forma de medir distancias.