

Variables aleatorias, probabilidad y valor esperado

Reinforcement Learning, segundo semestre

Ignacio Brevis

*Versión 1.0. Si encuentras algún error o tienes comentarios, escríbeme a
ignaciobrve@unisabana.edu.co.*

Resumen

Esta guía explica tres ideas principales: qué es una **variable aleatoria** (discreta), qué es una **probabilidad** (incluida la **probabilidad condicional**) y qué es un **valor esperado**. Cada concepto se presenta primero con ejemplos de la vida cotidiana; e.g., dados, monedas, el tiempo, una rifa; y después con un ejemplo de aprendizaje por refuerzo, un pequeño mundo de casillas de 5×5 . Al final hay 10 ejercicios con pistas y soluciones completas. **En esta guía trabajaremos únicamente con variables aleatorias discretas**, es decir, variables cuyos posibles valores se pueden enumerar.

Índice

1. Antes de empezar	2
1.1. Para qué sirve todo esto	2
1.2. Cómo leer esta guía	2
1.3. Una advertencia sobre la notación	2
1.4. El ejemplo que usaremos constantemente	3
2. Variables aleatorias	3
2.1. La idea, en lenguaje corriente	3
2.2. Por qué mayúsculas y minúsculas	4
2.3. Ejemplos de la vida diaria	4
2.4. Ejemplo en el gridworld	5
3. Probabilidad	5
3.1. Qué es un número de probabilidad	5
3.2. Las dos reglas que hay que recordar	5
3.3. La distribución como una tabla	6
3.4. Ejemplo en el gridworld	6
3.5. Cuando hay dos variables a la vez	7
4. Probabilidad condicional	7
4.1. La idea: reducir el mundo de posibilidades	7
4.2. La fórmula	8
4.3. Ejemplo con la tabla del paraguas	8
4.4. Independencia	8
4.5. Ejemplo en el gridworld	8

5. Valor esperado	9
5.1. Por qué no basta con la media de siempre	9
5.2. La definición	9
5.3. Ejemplos de la vida diaria	10
5.4. Una propiedad que se usa constantemente	10
5.5. Valor esperado condicional	11
5.6. Ejemplo en el gridworld	11
5.7. La política importa	11
6. Resumen	12
7. Ejercicios	12
8. Soluciones	14

1. Antes de empezar

1.1. Para qué sirve todo esto

En el aprendizaje por refuerzo (*reinforcement learning*, RL) un **agente** toma decisiones en un entorno y recibe **recompensas**. El agente no sabe de antemano qué va a pasar: hay azar de por medio. Por eso, casi todo lo que se dice en RL tiene esta forma:

*«Si estoy aquí y hago esto, ¿cuánta recompensa puedo esperar **en promedio**?»*

Esa frase contiene, escondidas, las tres ideas de esta guía. «Cuánta recompensa» es una **variable aleatoria**. «Si estoy aquí y hago esto» es una **condición**. Y «en promedio» es un **valor esperado**.

1.2. Cómo leer esta guía

- Los recuadros **grises** resumen la idea central de cada sección en una frase. Si sólo se leen esos recuadros, ya se ha entendido lo esencial.
- Los recuadros **azules** conectan la idea con el aprendizaje por refuerzo.
- Los ejemplos van siempre de lo cotidiano a lo técnico, nunca al revés.

1.3. Una advertencia sobre la notación

Las matemáticas usan letras porque escribir «el número que sale al tirar el dado» veinte veces seguidas es agotador. La notación no es un obstáculo: es una abreviatura.

Símbolo	Significa
X	una variable aleatoria
x	un valor concreto que X puede tomar
$p(x)$	la probabilidad de que X valga x
$p(x, y)$	la probabilidad de que X valga x y Y valga y
$p(x a)$	la probabilidad de que X valga x <i>sabiendo</i> que A vale a
$\mathbb{E}[X]$	el valor esperado (promedio) de X
$\mathbb{E}[X A = a]$	el promedio de X <i>sabiendo</i> que A vale a

1.4. El ejemplo que usaremos constantemente

Además de dados y monedas, usaremos un mundo de juguete muy común en RL: una cuadrícula de 5×5 casillas. Un robot se mueve por ella.

0	1	2	3	4
5	6	7	8	9
10	11	12	13	14
15	16	17	18	19
20	21	22	23	24

Las reglas son sencillas:

- Las 25 casillas se numeran del 0 al 24. Cada casilla es un **estado**.
- En cada turno el robot elige una de **5 acciones**: arriba, derecha, abajo, izquierda o quedarse quieto.
- El movimiento es **exacto**: si elige «derecha», va a la derecha, sin fallos. Si intenta salirse de la cuadrícula, choca contra la pared y se queda donde estaba.
- Después de moverse recibe una **recompensa**, que es un número:
 - -1 si choca contra una pared,
 - -1 si acaba en una casilla **naranja** (son celdas penalizadas),
 - $+1$ si acaba en la casilla **azul** (es el objetivo),
 - 0 si acaba en una casilla **blanca**.

Observación. Aquí hay un detalle que conviene subrayar desde ya, porque es la clave de todo lo que sigue: **el entorno no tiene ningún azar**. El movimiento es exacto y las recompensas están fijadas. Entonces, ¿de dónde sale la aleatoriedad? De la **decisión del robot**. Si el robot elige su acción tirando una moneda o un dado, la recompensa que reciba será impredecible. Toda la probabilidad de este ejemplo nace de ahí.

Observación. En este ejemplo, la casilla azul no es terminal: llegar a ella no termina el episodio. Si el robot está en la casilla azul y decide quedarse, recibe nuevamente una recompensa de $+1$.

2. Variables aleatorias

La idea en una frase. Una variable aleatoria es una **cantidad numérica cuyo valor viene determinado por el resultado de un fenómeno o experimento aleatorio**. Antes de observar el resultado, no sabemos qué valor tomará.

2.1. La idea, en lenguaje corriente

Tomemos un dado normal, de seis caras, y agitémoslo en la mano sin lanzarlo todavía. El valor que va a salir:

- es un **número** (no es un color ni una palabra);
- podría ser cualquiera de 1, 2, 3, 4, 5, 6 y ninguno más;

- aún no sabemos cuál será.

Eso es exactamente una variable aleatoria. Nótese que hacen falta las tres cosas. El color de un coche que pasa por la calle es incierto, pero no es un número, así que no es directamente una variable aleatoria (aunque podríamos convertirlo en una, asignando un número a cada color). Y el número de días que tiene una semana es un número, pero no es incierto: siempre es 7.

Definición 2.1 (Variable aleatoria). Una *variable aleatoria* asigna un valor numérico a cada posible resultado de un fenómeno aleatorio.

2.2. Por qué mayúsculas y minúsculas

Hay una convención de notación que confunde a todo el mundo al principio, así que la explicamos despacio:

Mayúscula X = la cantidad incierta, antes de saber nada.
Minúscula x = un valor concreto que esa cantidad podría tomar.

Es la diferencia entre «el número que saldrá al tirar el dado» y «el número 4». Con esta convención, la frase

«la probabilidad de que el dado saque un 4»

se escribe $\mathbb{P}(X = 4)$, y de forma abreviada, $p(4)$. Cuando queremos hablar de un valor cualquiera sin decidir cuál, escribimos $p(x)$.

Cuidado. En muchos textos de RL se usan minúsculas incluso para variables aleatorias, sobre todo cuando se habla de muestras: $x_1, x_2, x_3, \dots$ son los resultados de tirar el dado varias veces, y *siguen siendo* inciertos hasta que se tiran. La regla mayúscula/minúscula es una guía, no una ley.

2.3. Ejemplos de la vida diaria

Ejemplo 2.2 (El dado). X = el número que sale al tirar un dado de seis caras. Valores posibles: 1, 2, 3, 4, 5, 6.

Ejemplo 2.3 (La moneda). Una moneda no da un número, da «cara» o «cruz». Para convertirla en variable aleatoria, elegimos un código: $X = 1$ si sale cara, $X = 0$ si sale cruz. Valores posibles: 0, 1.

Este truco, de asignar 1 a «ocurrió» y 0 a «no ocurrió», es tan útil que tiene nombre propio: **variable indicadora**, y se escribe $\mathbf{1}_A$, donde A es el suceso que nos interesa.

Ejemplo 2.4 (La cafetería). X = número de personas que hay en la cola cuando llego mañana. Valores posibles: 0, 1, 2, 3, ... Es incierto, es un número, y sabemos más o menos qué rango esperar.

Ejemplo 2.5 (La rifa). Compro un boleto de 2 euros. X = lo que gano. Valores posibles: 100 (si me toca) o 0 (si no).

Ejemplo 2.6. No son variables aleatorias:

- Si ya hemos observado «que el dado salió 3», entonces 3 es una realización de la variable aleatoria. Ya no hay incertidumbre: es 3.
- «Mi color favorito». No es un número.
- «La temperatura de ebullición del agua a nivel del mar». Es un número, pero siempre el mismo.

2.4. Ejemplo en el gridworld

Volvamos al robot de la Sección 1.4. Supongamos que está en la **casilla 22** (fila de abajo, en el centro, justo debajo de la casilla azul) y que va a elegir su acción **al azar**, cada una de las cinco con la misma posibilidad.

Miremos qué pasa con cada acción:

Acción	Acaba en	Tipo de casilla	Recompensa
arriba	casilla 17	azul (objetivo)	+1
derecha	casilla 23	blanca	0
abajo	casilla 22	choca con la pared	-1
izquierda	casilla 21	naranja (penalizada)	-1
quedarse	casilla 22	blanca	0

Llamemos R a la recompensa que va a recibir el robot. ¿Es R una variable aleatoria? Sí, y cumple las tres condiciones: es un número, puede valer -1 , 0 o $+1$, y todavía no sabemos cuál porque depende de la acción que elija el azar.

Conexión con RL. En RL casi todo es una variable aleatoria: el **estado** S_t en el que estará el agente, la **acción** A_t que tomará, la **recompensa** R_{t+1} que recibirá. El subíndice t indica el instante de tiempo. Cuando aparece S_t , A_t , R_{t+1} , hay que leerlo como «el estado, la acción y la recompensa *del turno* t , que todavía no conocemos».

3. Probabilidad

La idea en una frase. La probabilidad de un valor es **cuánto de posible** es ese valor, medido con un número entre 0 y 1. Todas las probabilidades de una variable aleatoria, sumadas, dan exactamente 1.

3.1. Qué es un número de probabilidad

Una probabilidad es un número entre 0 y 1:

- 0 significa «imposible»;
- 1 significa «seguro»;
- 0.5 significa «tan probable como improbable»;
- 0.9 significa «muy probable, pero no garantizado».

A veces se escriben como porcentajes (0.25 es lo mismo que el 25 %) y a veces como fracciones ($1/4$). Son tres formas de escribir lo mismo. En esta guía usaremos sobre todo decimales, porque hacen las cuentas más fáciles.

3.2. Las dos reglas que hay que recordar

Propiedad 3.1 (Regla 1). *Toda probabilidad está entre 0 y 1. Nunca es negativa ni mayor que 1.*

Propiedad 3.2 (Regla 2). Si listamos **todos** los valores que puede tomar una variable aleatoria y sumamos sus probabilidades, el resultado es exactamente 1.

La segunda regla dice algo muy razonable: *algo* tiene que pasar. Si tiramos un dado, saldrá alguno de los seis números; la posibilidad total está repartida entre ellos y no se pierde nada por el camino.

Ejemplo 3.3 (El dado justo). Los seis resultados son igual de posibles, así que se reparte 1 entre 6:

$$p(1) = p(2) = p(3) = p(4) = p(5) = p(6) = \frac{1}{6} \approx 0.1667.$$

Comprobación de la Regla 2: $\frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{6}{6} = 1$.

Ejemplo 3.4 (Una moneda trucada). Una moneda que sale cara el 70% de las veces. Con el código $X = 1$ para cara y $X = 0$ para cruz:

$$p(1) = 0.7, \quad p(0) = 0.3.$$

Comprobación: $0.7 + 0.3 = 1$. Correcto.

3.3. La distribución como una tabla

Cuando alguien dice «la **distribución** de X » (en el caso de variable aleatorias discretas) está diciendo algo mucho menos intimidante de lo que suena: la **lista completa** de los valores posibles junto a sus probabilidades. Nada más. Para la moneda trucada:

Valor x	Probabilidad $p(x)$
0 (cruz)	0.3
1 (cara)	0.7
Total	1

Una tabla así es una distribución válida si (a) ninguna probabilidad es negativa y (b) la columna suma 1. Si falla cualquiera de las dos, la tabla está mal.

3.4. Ejemplo en el gridworld

Volvamos al robot en la casilla 22, eligiendo su acción al azar entre las cinco. Cada acción tiene probabilidad $1/5 = 0.2$. En RL, esta forma de elegir se llama **política**, y se escribe $\pi(a|s)$: la probabilidad de tomar la acción a estando en el estado s . Aquí, $\pi(a|22) = 0.2$ para las cinco acciones.

Ahora podemos construir la distribución de la recompensa R . Miramos la tabla de la sección anterior y agrupamos por recompensa:

- $R = +1$ ocurre sólo con *arriba*: 1 acción de 5, luego $p(+1) = 0.2$.
- $R = 0$ ocurre con *derecha* o *quedarse*: 2 acciones de 5, luego $p(0) = 0.4$.
- $R = -1$ ocurre con *abajo* (pared) o *izquierda* (penalizada): 2 de 5, luego $p(-1) = 0.4$.

Recompensa r	Probabilidad $p(r)$
-1	0.4
0	0.4
+1	0.2
Total	1

Comprobación: $0.4 + 0.4 + 0.2 = 1$. Correcto. Fíjese en lo que acabamos de hacer: partiendo de un entorno *sin ningún azar* y de un robot que decide al azar, hemos obtenido una recompensa que es genuinamente aleatoria.

3.5. Cuando hay dos variables a la vez

A menudo interesan dos cantidades inciertas al mismo tiempo. Por ejemplo: $X = \text{«¿llueve?»}$ e $Y = \text{«¿llevo paraguas?»}$. Entonces la tabla tiene dos entradas y se llama **probabilidad conjunta**, escrita $p(x, y)$:

	Paraguas: sí	Paraguas: no	Total fila
Llueve: sí	0.25	0.05	0.30
Llueve: no	0.10	0.60	0.70
Total columna	0.35	0.65	1.00

Las cuatro casillas centrales suman 1: $0.25 + 0.05 + 0.10 + 0.60 = 1$. Correcto.

Los totales de los márgenes tienen nombre propio: se llaman **probabilidades marginales**, y salen simplemente de sumar la fila o la columna. Por ejemplo, la probabilidad de que llueva, sin importar el paraguas, es $0.25 + 0.05 = 0.30$.

Observación. Se llaman «marginales» porque se escriben en el margen de la tabla. El nombre suena técnico, pero no lo es en absoluto.

4. Probabilidad condicional

La idea en una frase. La probabilidad condicional es la probabilidad **después de recibir una información**. Al enterarnos de algo, descartamos parte de los escenarios posibles y recalculamos con los que quedan.

4.1. La idea: reducir el mundo de posibilidades

Tiro un dado y, sin enseñárselo a nadie, digo: «ha salido un número par». ¿Cuál es ahora la probabilidad de que sea un 4?

Antes de mi comentario, había seis resultados posibles y la respuesta era $1/6$. Pero mi comentario ha eliminado tres de ellos: el 1, el 3 y el 5 ya no pueden ser. Quedan tres candidatos, 2, 4 y 6, todos igual de posibles. La respuesta es ahora $1/3$.

Condicionar = descartar los escenarios incompatibles con la información y redistribuir las probabilidades de los escenarios que quedan para que vuelvan a sumar 1

Esto se escribe

$$p(X = 4 | X \text{ es par}) = \frac{1}{3},$$

y la barra vertical $|$ se lee «**dado que**» o «**sabiendo que**».

Cuidado. La redistribucion de probabilidades se hace a corde a las probabilidades restantes. Si los escenarios que quedan son igualmente probables, como en el ejemplo del dado, entonces la probabilidad se reparte por igual entre ellos.

4.2. La fórmula

Definición 4.1 (Probabilidad condicional).

$$p(x|a) = \frac{p(x, a)}{p(a)}, \quad (p(a) > 0).$$

Parece abstracta, pero es literalmente lo que hicimos con el dado. Abajo va $p(a)$, la probabilidad de la información que hemos recibido: es el «mundo que sobrevive». Arriba va $p(x, a)$, la probabilidad de que ocurra lo que preguntamos *y además* sea compatible con esa información. Dividir es repartir el 1 entre los supervivientes.

Con el dado: $p(\text{par}) = 3/6$ y $p(\text{sale 4 y es par}) = 1/6$ (porque el 4 ya es par, así que las dos cosas juntas son sólo «sale 4»). Entonces

$$p(4|\text{par}) = \frac{1/6}{3/6} = \frac{1}{3}.$$

Coincide con lo que habíamos razonado a mano.

4.3. Ejemplo con la tabla del paraguas

Usemos la tabla de la sección anterior. *Sabiendo que llueve*, ¿cuál es la probabilidad de que lleve paraguas?

La información «llueve» nos deja sólo en la primera fila. Esa fila suma 0.30, y dentro de ella el caso «con paraguas» vale 0.25. Por tanto:

$$p(\text{paraguas} | \text{llueve}) = \frac{0.25}{0.30} \approx 0.833.$$

Comparémoslo con la probabilidad *sin* información: $p(\text{paraguas}) = 0.35$. Saber que llueve ha cambiado nuestra estimación de 0.35 a 0.83. Eso significa que las dos variables están **relacionadas**: una nos informa sobre la otra.

4.4. Independencia

Definición 4.2 (Independencia). Dos variables son *independientes* si conocer una **no cambia nada** sobre la otra, es decir, si

$$p(x|y) = p(x).$$

Ejemplo 4.3. Tiro dos dados. Saber que el primero sacó un 6 no me dice absolutamente nada sobre el segundo: sigue siendo 1/6 para cada cara. Los dos dados son independientes.

En cambio, lluvia y paraguas **no** son independientes, como acabamos de ver. Y el resultado del dado y «el dado es par» tampoco lo son, obviamente.

4.5. Ejemplo en el gridworld

La probabilidad condicional es *la* herramienta natural del gridworld, porque la pregunta de fondo siempre es «¿qué recompensa cabe esperar **desde esta casilla**?». La casilla es la información; la recompensa es lo que preguntamos.

Ya calculamos la distribución de R desde la casilla 22. En notación condicional:

$$p(R = +1|S = 22) = 0.2, \quad p(R = 0|S = 22) = 0.4, \quad p(R = -1|S = 22) = 0.4.$$

Hagamos ahora lo mismo desde la **casilla 11**, para comparar. Sus vecinas son:

Acción	Acaba en	Tipo de casilla	Recompensa
arriba	casilla 6	naranja	-1
derecha	casilla 12	naranja	-1
abajo	casilla 16	naranja	-1
izquierda	casilla 10	blanca	0
quedarse	casilla 11	blanca	0

Con la misma política al azar:

$$p(R = -1|S = 11) = 0.6, \quad p(R = 0|S = 11) = 0.4, \quad p(R = +1|S = 11) = 0.$$

Las dos distribuciones son distintas, y esa diferencia es información valiosa: la casilla 11 está rodeada de celdas penalizadas y desde ella es *imposible* ganar recompensa en un turno, mientras que desde la 22 hay un 20 % de posibilidades. Un agente que aprenda esta diferencia habrá aprendido algo útil sobre el mapa.

Conexión con RL. El símbolo $\pi(a|s)$ que aparece en cualquier libro de RL es exactamente una probabilidad condicional: «la probabilidad de elegir la acción a , sabiendo que estoy en el estado s ». En un problema tabular como este, una **política** puede representarse como una tabla de probabilidades condicionales, una fila por estado. Igualmente, $p(s'|s, a)$ es «la probabilidad de acabar en s' , sabiendo que estaba en s y tomé la acción a »: describe cómo se comporta el entorno. En nuestro gridworld esa segunda tabla es aburrida, porque el movimiento es exacto: vale 1 para una casilla y 0 para todas las demás.

5. Valor esperado

La idea en una frase. El valor esperado es el **promedio a largo plazo**: lo que obtendríamos por turno si repitiéramos el experimento *muchas* veces. Se calcula multiplicando cada valor por su probabilidad y sumando.

5.1. Por qué no basta con la media de siempre

La media de 1, 2, 3, 4, 5, 6 es 3.5: se suman y se divide entre seis. Eso funciona porque las seis caras del dado son **igual de probables**.

Pero supongamos un dado trucado que saca 6 la mitad de las veces. Ahora sumar y dividir entre seis daría una respuesta equivocada, porque trataría al 6 igual que al 1, y el 6 aparece mucho más. Hace falta un promedio en el que **cada valor pese según cuánto aparece**. Ese es el valor esperado.

5.2. La definición

Definición 5.1 (Valor esperado). Si X puede tomar los valores $x_1, x_2, \dots, x_n$ con probabilidades $p(x_1), p(x_2), \dots, p(x_n)$, su *valor esperado* es

$$\mathbb{E}[X] = x_1 \cdot p(x_1) + x_2 \cdot p(x_2) + \dots + x_n \cdot p(x_n).$$

En palabras: **cada valor, multiplicado por su probabilidad, todo sumado**. Es una receta de tres pasos:

1. Generar la tabla de valores y probabilidades.
2. Multiplicar, en cada fila, valor $\times$ probabilidad.
3. Sumar la columna de resultados.

También se le llama **esperanza**.

5.3. Ejemplos de la vida diaria

Ejemplo 5.2 (El dado justo).

$$\mathbb{E}[X] = 1\left(\frac{1}{6}\right) + 2\left(\frac{1}{6}\right) + 3\left(\frac{1}{6}\right) + 4\left(\frac{1}{6}\right) + 5\left(\frac{1}{6}\right) + 6\left(\frac{1}{6}\right) = 3.5.$$

Como todas las probabilidades son iguales, coincide con la media de siempre.

Ejemplo 5.3 (El dado trucado). Un dado que saca 6 con probabilidad 0.5, y cada uno de los otros cinco números con probabilidad 0.1:

$$\mathbb{E}[X] = 1(0.1) + 2(0.1) + 3(0.1) + 4(0.1) + 5(0.1) + 6(0.5) = 0.1 + 0.2 + 0.3 + 0.4 + 0.5 + 3.0 = 4.5.$$

Mayor que 3.5, como cabía esperar: el dado está sesgado hacia los números altos.

Ejemplo 5.4 (La rifa). Un boleto cuesta 2 euros. Hay 100 boletos y un único premio de 100 euros. Sea X = lo que gano (sin contar lo que pagué):

$$\mathbb{E}[X] = 100(0.01) + 0(0.99) = 1.$$

En promedio gano 1 euro por boleto... y pago 2. Es decir, cada boleto me cuesta 1 euro en promedio. Ésta es exactamente la cuenta que hacen las loterías, y explica por qué a la larga siempre gana la banca.

Cuidado. El valor esperado **no tiene por qué ser un valor posible**. La esperanza del dado es 3.5, y un dado no puede sacar 3.5 jamás. Y la rifa nunca paga 1 euro: paga 0 o paga 100.

Esto no es un fallo de la definición. El valor esperado no responde a «¿qué va a pasar?», sino a «si esto pasara mil veces, ¿cuánto tocaría por vez?». Es un promedio, y los promedios casi nunca son valores individuales: la familia media tiene 1.3 hijos.

5.4. Una propiedad que se usa constantemente

Propiedad 5.5 (Linealidad). *El promedio de una suma es la suma de los promedios:*

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

Y si se multiplica todo por un número fijo c , el promedio se multiplica igual:

$$\mathbb{E}[cX] = c\mathbb{E}[X].$$

Ejemplo 5.6. Tiro dos dados y sumo. El promedio de la suma es $3.5 + 3.5 = 7$, sin necesidad de listar los 36 resultados posibles.

Observación. Lo notable de esta propiedad es que funciona **siempre**, incluso cuando las dos cantidades están relacionadas entre sí. Es lo que permite, en RL, partir una recompensa total en trozos y promediar cada trozo por separado, aunque los trozos dependan unos de otros.

5.5. Valor esperado condicional

Ahora juntamos las dos últimas ideas. Un **valor esperado condicional** es, simplemente, un promedio calculado *después* de recibir información:

Definición 5.7 (Valor esperado condicional). $\mathbb{E}[X|A = a]$ es el promedio de X **sabiendo que** A vale a . Se calcula igual que antes, pero usando las probabilidades condicionales:

$$\mathbb{E}[X|A = a] = x_1 \cdot p(x_1|a) + x_2 \cdot p(x_2|a) + \cdots + x_n \cdot p(x_n|a).$$

Ejemplo 5.8 (El dado, otra vez). Sin información, $\mathbb{E}[X] = 3.5$. Pero *sabiendo que salió par*, sólo quedan 2, 4, 6 con probabilidad $1/3$ cada uno:

$$\mathbb{E}[X|\text{par}] = 2 \left(\frac{1}{3}\right) + 4 \left(\frac{1}{3}\right) + 6 \left(\frac{1}{3}\right) = 4.$$

La información ha subido el promedio de 3.5 a 4. Tiene sentido: hemos descartado los números impares; en este caso, los pares tienen un promedio mayor.

5.6. Ejemplo en el gridworld

Volvamos al robot en la casilla 22 con la política al azar. Ya tenemos su tabla de recompensas, así que sólo hay que multiplicar y sumar:

$$\mathbb{E}[R|S = 22] = (-1)(0.4) + (0)(0.4) + (+1)(0.2) = -0.4 + 0 + 0.2 = -0.2.$$

También podemos calcularlo acción por acción, que es como suele escribirse en RL: cada acción tiene probabilidad 0.2 y su propia recompensa,

$$\mathbb{E}[R|S = 22] = 0.2(+1) + 0.2(0) + 0.2(-1) + 0.2(-1) + 0.2(0) = -0.2.$$

Mismo resultado, como debe ser.

Y desde la casilla 11:

$$\mathbb{E}[R|S = 11] = 0.2(-1) + 0.2(-1) + 0.2(-1) + 0.2(0) + 0.2(0) = -0.6.$$

Comparemos los dos números: -0.2 frente a -0.6 . **La casilla 22 es mejor que la 11**, si sólo miramos un turno.

5.7. La política importa

Hasta ahora el robot elegía al azar, lo cual es bastante ineficiente. ¿Y si eligiera mejor? Supongamos que desde la casilla 22 el robot ha aprendido a subir casi siempre:

$$\pi(\text{arriba}|22) = 0.6, \quad \pi(\text{derecha}|22) = 0.2, \quad \pi(\text{quedarse}|22) = 0.2,$$

y probabilidad 0 para abajo e izquierda. Entonces

$$\mathbb{E}[R|S = 22] = 0.6(+1) + 0.2(0) + 0.2(0) = 0.6.$$

Hemos pasado de -0.2 a $+0.6$ **sin cambiar nada del entorno**: el mapa es el mismo, las recompensas son las mismas. Lo único que ha cambiado es cómo decide el robot.

Conexión con RL. Esto es, en miniatura, todo el aprendizaje por refuerzo. El objetivo es encontrar la política π que haga los valores esperados lo más altos posible.

La siguiente pieza para acercarnos a las definiciones habituales de RL es el **horizonte**

temporal : aquí hemos mirado sólo el turno siguiente, mientras que un agente de verdad se preocupa por toda la cadena de recompensas futuras, $R_{t+1}, R_{t+2}, R_{t+3}, \dots$, sumadas con un descuento γ que da menos peso a lo que está más lejos. El **valor de un estado** se define entonces como

$$v_{\pi}(s) = \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \mid S_t = s],$$

que, leída con lo que ya sabemos, dice: «el promedio de toda la recompensa futura, sabiendo que ahora estoy en el estado s ». Es un valor esperado condicional, ni más ni menos.

6. Resumen

Concepto	En una frase	Cómo se escribe
Variable aleatoria	Un número que aún no conocemos	X
Valor concreto	Uno de los resultados posibles	x
Probabilidad	Cuánto de posible es un valor	$p(x)$, entre 0 y 1
Distribución	La tabla completa de valores y probabilidades	la columna suma 1
Conjunta	Probabilidad de dos cosas a la vez	$p(x, y)$
Condicional	Probabilidad después de saber algo	$p(x a) = \frac{p(x, a)}{p(a)}$
Independencia	Saber una no informa sobre la otra	$p(x y) = p(x)$
Valor esperado	Promedio ponderado por probabilidad	$x_1 p(x_1) + \dots + x_n p(x_n)$
Esperado condicional	Promedio después de saber algo	$\mathbb{E}[X A = a]$
Linealidad	El promedio de la suma es la suma	$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$

7. Ejercicios

Cada ejercicio incluye una *pista*. Las soluciones completas están en la Sección 8. Conviene intentar el ejercicio antes de leer la pista, y la pista antes de leer la solución.

Ejercicio 1 (¿Es una variable aleatoria?). Diga cuáles de las siguientes cantidades son variables aleatorias y, en las que no lo sean, explique cuál de las tres condiciones falla.

- (a) El número de correos que recibiré mañana.
- (b) El número de letras de la palabra «casa».
- (c) El equipo que ganará el partido del domingo.

- (d) Los minutos que tardaré en llegar al trabajo mañana.
- (e) La altura de la Torre Eiffel.

Pista: las tres condiciones son: (i) es un número, (ii) puede tomar varios valores, (iii) todavía no sabemos cuál.

Ejercicio 2 (¿Distribución válida?). ¿Cuáles de estas tablas son distribuciones de probabilidad válidas?

(a)		(b)		(c)	
x	$p(x)$	x	$p(x)$	x	$p(x)$
1	0.5	0	0.6	-1	0.5
2	0.3	1	0.6	0	-0.2
3	0.2			1	0.7

Pista: compruebe las dos reglas de la Sección 3.2 en cada tabla, una por una.

Ejercicio 3 (Dados). Considere lo siguiente:

- (a) Calcule el valor esperado de un dado justo de **cuatro** caras (1, 2, 3, 4).
- (b) Un dado de cuatro caras está trucado: saca el 4 con probabilidad 0.7 y cada uno de los otros tres números con probabilidad 0.1. Calcule su valor esperado.
- (c) Compare los dos resultados y explique la diferencia en una frase.

Pista: en (b), compruebe primero que las probabilidades suman 1 antes de hacer nada más.

Ejercicio 4 (¿Merece la pena jugar?). Un juego de feria cuesta 3 euros por partida. Se gana 20 euros con probabilidad 0.1, se gana 5 euros con probabilidad 0.2, y no se gana nada el resto de las veces.

- (a) ¿Cuál es la probabilidad de no ganar nada?
- (b) Calcule el valor esperado de lo que se gana.
- (c) Descontando los 3 euros de la partida, ¿conviene jugar?

Pista: para (a), use que todas las probabilidades suman 1.

Ejercicio 5 (La tabla del paraguas). Con la tabla conjunta de la Sección 3.5:

- (a) Calcule $p(\text{lleuve} | \text{llevo paraguas})$.
- (b) Calcule $p(\text{lleuve} | \text{no llevo paraguas})$.
- (c) ¿Son independientes las dos variables? Justifíquelo comparando con $p(\text{lleuve})$.

Pista: en (a) la información es «llevo paraguas», así que el mundo que sobrevive es la *columna* del paraguas, no la fila.

Ejercicio 6 (Gridworld: la casilla 8). El robot está en la casilla 8 y elige su acción al azar entre las cinco.

- (a) Construya la tabla de las cinco acciones: dónde acaba, qué tipo de casilla es y qué recompensa recibe.
- (b) Escriba la distribución de R y compruebe que suma 1.
- (c) Calcule $\mathbb{E}[R | S = 8]$.

Pista: la casilla 8 está en la segunda fila, cuarta columna. Mire el mapa de la Sección 1.4 y localice sus cuatro vecinas antes de calcular nada.

Ejercicio 7 (Gridworld: cambiar de política). Siga en la casilla 8, pero ahora el robot usa esta política:

$$\pi(\text{abajo}|8) = 0.7, \quad \pi(\text{izquierda}|8) = 0.1, \quad \pi(\text{quedarse}|8) = 0.2,$$

y 0 para las demás acciones.

- (a) Compruebe que es una política válida.
- (b) Calcule $\mathbb{E}[R|S = 8]$ con esta política.
- (c) Compare con el resultado del ejercicio anterior. ¿Ha mejorado el robot?

Pista: las acciones con probabilidad 0 aportan 0 a la suma, así que pueden omitirse del cálculo.

Ejercicio 8 (Gridworld: la casilla azul). El robot está en la casilla 17, la azul, y elige al azar entre las cinco acciones.

- (a) Calcule $\mathbb{E}[R|S = 17]$.
- (b) El resultado es negativo, a pesar de estar en la casilla objetivo. Explique por qué.
- (c) ¿Qué política haría que este valor fuera lo más alto posible, y cuánto valdría?

Pista: para (b), mire qué hay alrededor de la casilla 17 en el mapa. Para (c), recuerde que quedarse en la casilla azul también da recompensa.

Ejercicio 9 (La bolsa de bolas). Una bolsa tiene 10 bolas: 6 rojas y 4 azules. De las rojas, 2 tienen una estrella dibujada. De las azules, 3 tienen estrella. Saco una bola al azar.

- (a) ¿Cuál es la probabilidad de que tenga estrella?
- (b) Sabiendo que la bola que he sacado es azul, ¿cuál es la probabilidad de que tenga estrella?
- (c) ¿Son independientes el color y la estrella?

Pista: para (b) no hace falta la fórmula: basta con mirar sólo las 4 bolas azules y contar.

Ejercicio 10 (Dos dados). Considere lo siguiente:

- (a) Use la linealidad para calcular el valor esperado de la suma de dos dados justos de seis caras.
- (b) Un amigo dice: «entonces si tiro dos dados, lo más normal es que salga 7». ¿Es correcto lo que dice? ¿Y es lo mismo que dice el valor esperado?
- (c) ¿Cuál sería el valor esperado de la suma de *diez* dados?

Pista: en (b), distinga entre «el resultado más frecuente» y «el promedio a largo plazo». Aquí resultan coincidir, pero por razones distintas; piense en el ejemplo del dado de una sola tirada, cuyo promedio es 3.5.

8. Soluciones

Solución 1.

- (a) **Sí.** Es un número $(0, 1, 2, \dots)$, incierto, con varios valores posibles.
- (b) **No.** Es un número, pero siempre vale 4. Falla la condición (iii): no hay incertidumbre.
- (c) **No directamente.** Es incierto y tiene varios resultados posibles, pero «el Betis» no es un número. Falla (i). Ahora bien, se puede convertir fácilmente en variable aleatoria con el truco de la indicadora: $X = 1$ si gana el equipo local, $X = 0$ si no.
- (d) **Sí.** Es un número, incierto y con muchos valores posibles.
- (e) **No.** Es un número, pero es siempre el mismo (330 metros aproximadamente). Falla (iii).

Solución 2.

- (a) **Válida.** Todas las probabilidades están entre 0 y 1, y $0.5 + 0.3 + 0.2 = 1$.
- (b) **No válida.** Cada número por separado es correcto, pero $0.6 + 0.6 = 1.2$, que es mayor que 1. Se está prometiendo más posibilidad de la que existe.
- (c) **No válida.** Aunque $0.5 + (-0.2) + 0.7 = 1$, hay una probabilidad negativa, y eso no significa nada: no existe algo «menos que imposible».

Solución 3.

- (a) Cada cara tiene probabilidad $1/4 = 0.25$:

$$\mathbb{E}[X] = 1(0.25) + 2(0.25) + 3(0.25) + 4(0.25) = 0.25 + 0.5 + 0.75 + 1 = 2.5.$$

- (b) Primero la comprobación: $0.1 + 0.1 + 0.1 + 0.7 = 1$. Correcto. Entonces

$$\mathbb{E}[X] = 1(0.1) + 2(0.1) + 3(0.1) + 4(0.7) = 0.1 + 0.2 + 0.3 + 2.8 = 3.4.$$

- (c) El dado trucado tiene un promedio bastante más alto (3.4 frente a 2.5) porque casi tres cuartas partes de las tiradas dan el valor máximo, que además es el más grande de todos.

Solución 4.

- (a) Las probabilidades tienen que sumar 1, así que $p(0) = 1 - 0.1 - 0.2 = 0.7$.

- (b)

$$\mathbb{E}[X] = 20(0.1) + 5(0.2) + 0(0.7) = 2 + 1 + 0 = 3.$$

- (c) El premio esperado es exactamente 3 euros y la partida cuesta 3 euros, así que el balance esperado es $3 - 3 = 0$. Es un juego **justo**: a la larga ni se gana ni se pierde.

Merece la pena notar dos cosas. Primera: un juego justo es rarísimo en la vida real; las ferias y los casinos ajustan los premios para que el balance esperado sea negativo para el jugador. Segunda: «balance esperado cero» no significa que se vaya a salir con lo mismo con lo que se entró. En una sola partida lo más probable (70 %) es perder 3 euros. El cero sólo aparece si se juega muchísimas veces.

Solución 5.

- (a) La información es «llevo paraguas», así que trabajamos en la primera *columna*, que suma 0.35. Dentro de ella, el caso «llueve» vale 0.25:

$$p(\text{llueve} \mid \text{paraguas}) = \frac{0.25}{0.35} \approx 0.714.$$

- (b) Ahora la columna «sin paraguas», que suma 0.65, y dentro de ella «llueve» vale 0.05:

$$p(\text{llueve} \mid \text{no paraguas}) = \frac{0.05}{0.65} \approx 0.077.$$

- (c) **No son independientes.** Sin ninguna información, $p(\text{llueve}) = 0.30$. Al saber que llevo paraguas, la estimación sube a 0.71; al saber que no lo llevo, baja a 0.08. La información cambia mucho el resultado, luego las dos variables están relacionadas.

Obsérvese además que hemos aprendido algo sobre la lluvia mirando el paraguas, aunque el paraguas evidentemente no causa la lluvia. La probabilidad condicional habla de *información*, no de causas.

Solución 6. La casilla 8 está en la segunda fila, cuarta columna. Sus vecinas son: arriba la 3, a la derecha la 9, abajo la 13 y a la izquierda la 7.

	Acción	Acaba en	Tipo	Recompensa
(a)	arriba	casilla 3	blanca	0
	derecha	casilla 9	blanca	0
	abajo	casilla 13	blanca	0
	izquierda	casilla 7	naranja	-1
	quedarse	casilla 8	blanca	0

(b) Cuatro de las cinco acciones dan 0 y una da -1:

$$p(R = 0|S = 8) = 0.8, \quad p(R = -1|S = 8) = 0.2.$$

Comprobación: $0.8 + 0.2 = 1$. Correcto. (El valor +1 no aparece: desde la casilla 8 es imposible llegar a la azul en un solo turno.)

(c)

$$\mathbb{E}[R|S = 8] = 0(0.8) + (-1)(0.2) = -0.2.$$

Solución 7.

(a) $0.7 + 0.1 + 0.2 + 0 + 0 = 1$, y ninguna probabilidad es negativa. Es válida.

(b) Sólo tres acciones tienen probabilidad distinta de cero. Sus recompensas, de la tabla anterior, son: abajo $\rightarrow 0$, izquierda $\rightarrow -1$, quedarse $\rightarrow 0$.

$$\mathbb{E}[R|S = 8] = 0.7(0) + 0.1(-1) + 0.2(0) = -0.1.$$

(c) Ha mejorado: de -0.2 a -0.1. La razón es que la nueva política casi nunca elige ir a la izquierda, que era la única acción mala desde la casilla 8.

Un detalle interesante: la política *no* ha llegado a lo mejor posible. Si el robot pusiera probabilidad 0 a la izquierda, obtendría $\mathbb{E}[R|S = 8] = 0$, que es el máximo alcanzable desde esa casilla en un turno. Aun así, en RL no siempre conviene eliminar del todo una acción: mantener algo de probabilidad en acciones aparentemente malas es lo que permite al agente seguir *explorando* y descubrir cosas que no sabía.

Solución 8. La casilla 17 está en la cuarta fila, tercera columna. Vecinas: arriba la 12, a la derecha la 18, abajo la 22, a la izquierda la 16.

	Acción	Acaba en	Tipo	Recompensa
(a)	arriba	casilla 12	naranja	-1
	derecha	casilla 18	naranja	-1
	abajo	casilla 22	blanca	0
	izquierda	casilla 16	naranja	-1
	quedarse	casilla 17	azul	+1

$$\mathbb{E}[R|S = 17] = 0.2(-1) + 0.2(-1) + 0.2(0) + 0.2(-1) + 0.2(+1) = -0.4.$$

- (b) Porque la casilla azul está **rodeada de celdas penalizadas**: tres de sus cuatro vecinas son naranjas. Estar en el objetivo no sirve de nada si uno se marcha de él al azar. Con esta política, el robot abandona la casilla azul cuatro de cada cinco turnos, y tres de esas cuatro veces cae en una celda penalizada.
- (c) La mejor política es **quedarse quieto siempre**: $\pi(\text{quedarse}|17) = 1$ y 0 para el resto. Entonces

$$\mathbb{E}[R|S = 17] = 1(+1) = +1,$$

que es el máximo posible, ya que +1 es la mayor recompensa que existe en este mundo.

Esto ilustra algo importante: el valor de una situación **no es una propiedad del mapa**, sino del mapa *y* de la política. La misma casilla 17 vale -0.4 con un robot que decide al azar y $+1$ con un robot que sabe lo que hace.

Solución 9.

- (a) Hay 2 estrellas entre las rojas y 3 entre las azules, en total 5 estrellas de 10 bolas:

$$p(\text{estrella}) = \frac{5}{10} = 0.5.$$

- (b) Si sabemos que es azul, el mundo se reduce a las 4 bolas azules, de las cuales 3 tienen estrella:

$$p(\text{estrella} \mid \text{azul}) = \frac{3}{4} = 0.75.$$

Con la fórmula sale lo mismo: $p(\text{azul y estrella}) = 3/10 = 0.3$ y $p(\text{azul}) = 4/10 = 0.4$, luego $0.3/0.4 = 0.75$.

- (c) **No**. Sin información, la probabilidad de estrella es 0.5; sabiendo que la bola es azul, sube a 0.75. Como la información cambia el resultado, no son independientes: el color *dice algo* sobre la estrella.

Solución 10.

- (a) Cada dado tiene valor esperado 3.5, así que por linealidad

$$\mathbb{E}[X + Y] = 3.5 + 3.5 = 7.$$

Lo notable es que no hemos tenido que enumerar los 36 resultados posibles de la suma. Ése es todo el valor de la propiedad de linealidad.

- (b) Lo que dice el amigo es cierto, pero **no es lo que dice el valor esperado**, y conviene no confundir las dos afirmaciones.

Es cierto que 7 es el resultado *más frecuente* de sumar dos dados: hay seis formas de conseguirlo (1+6, 2+5, 3+4, 4+3, 5+2, 6+1), más que para cualquier otra suma. Pero eso es una coincidencia afortunada de este caso concreto.

El valor esperado dice otra cosa: que si tiramos los dos dados muchísimas veces y hacemos el promedio de todas las sumas, ese promedio se acercará a 7. Que además el 7 sea el resultado más común es información adicional que el valor esperado no proporciona.

La prueba de que son cosas distintas es el dado de una sola tirada: su valor esperado es 3.5, que no sólo no es el resultado más frecuente, sino que ni siquiera es un resultado posible.

- (c) Por linealidad, diez dados dan $3.5 \times 10 = 35$.