

Fundamentos de probabilidad

Reinforcement Learning, segundo semestre

Ignacio Brevis

(guía de estudio basada en los Apéndices A y B del libro de S. Zhao)

*Versión 1.0. Si encuentras algún error o tienes comentarios, escríbeme a
ignaciobrve@unisabana.edu.co.*

Resumen

El aprendizaje por refuerzo (*reinforcement learning*, RL), en el fondo, trata sobre **estimar esperanzas** a partir de muestras. El valor de un estado es una esperanza; el gradiente de política es una esperanza; los algoritmos TD, Sarsa y Q-learning son procedimientos estocásticos cuya corrección se enuncia en términos de convergencia *casi segura*. Esta guía reúne, de forma autocontenida, el mínimo indispensable de teoría de la probabilidad para leer sin problemas un texto de RL. La Parte I cubre el material elemental (Apéndice A) y la Parte II introduce la probabilidad basada en teoría de la medida (Apéndice B), que es la que da sentido preciso a expresiones como $\mathbb{E}[X|Y]$ y a frases como «el algoritmo converge con probabilidad 1». Al final se incluyen 12 ejercicios con pistas y soluciones completas.

Índice

1. Introducción: ¿por qué probabilidad?	2
Parte I: Probabilidad elemental	3
2. Variables aleatorias y sucesiones estocásticas	3
3. Probabilidad conjunta, condicional e independencia	3
3.1. Definiciones básicas	3
3.2. Ley de la probabilidad total y regla de la cadena	4
4. Esperanza	4
4.1. Linealidad	4
4.2. Esperanza condicional y ley de la esperanza total	5
4.3. Gradiente de una esperanza	6
4.4. Varianza y covarianza	6
Parte II: Probabilidad con teoría de la medida	6
5. ¿Por qué hace falta más rigor?	6
6. La tripleta de probabilidad	7
7. Variables aleatorias (formalmente)	7
8. Funciones indicadoras y esperanza de variables simples	7
9. La esperanza condicional como variable aleatoria	8

10.Modos de convergencia estocástica	9
10.1. Relaciones entre los modos	10
11.Resumen de fórmulas clave	11
12.Ejercicios	11
13.Soluciones	13

1. Introducción: ¿por qué probabilidad?

Un agente de RL interactúa con un entorno generando una trayectoria

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, \dots$$

Todo en esa lista es aleatorio: el estado siguiente lo decide el entorno mediante $p(s'|s, a)$, la acción la decide la política mediante $\pi(a|s)$ y la recompensa mediante $p(r|s, a)$. El objeto central de la teoría, el **valor de estado**, se define como una esperanza condicional:

$$v_\pi(s) \stackrel{\text{def}}{=} \mathbb{E}[G_t \mid S_t = s], \quad G_t \stackrel{\text{def}}{=} R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

Por tanto, prácticamente cada manipulación algebraica que se hace en RL (como derivar la ecuación de Bellman, justificar el muestreo de Monte Carlo, probar que TD converge) es una manipulación de esperanzas. Las herramientas que necesitamos son esencialmente cuatro:

- (I) la **linealidad de la esperanza**;
- (II) la **ley de la esperanza total** (o *propiedad de la torre*);
- (III) la noción de **independencia condicional**, que formaliza la propiedad de Markov;
- (IV) un vocabulario preciso de **modos de convergencia** de sucesiones de variables aleatorias.

Observación. La Parte II (teoría de la medida) es *opcional*. Es *relevante* si se quiere comprender las demostraciones de convergencia de los Capítulos 6 y 7 de Zhao (aproximación estocástica, Robbins–Monro, teorema de Dvoretzky), donde aparece el concepto de «convergencia casi segura» (almost sure convergence).

Notación

Símbolo	Significado
X, Y, Z	variables aleatorias (mayúsculas)
x, y, z	valores concretos que pueden tomar (minúsculas)
$p(x)$	abreviatura de $\mathbb{P}(X = x)$
$p(x, y)$	probabilidad conjunta $\mathbb{P}(X = x, Y = y)$
$p(x a)$	probabilidad condicional $\mathbb{P}(X = x A = a)$
$\mathbb{E}[X]$	esperanza (valor esperado, media) de X
$\text{var}(X)$	varianza de X
$\mathbf{1}_A$	función indicadora del evento A
$(\Omega, \mathcal{F}, \mathbb{P})$	tripleta de probabilidad
$\xrightarrow{\text{c.s.}}$	convergencia casi segura

En todo el texto suponemos, salvo mención expresa, que las variables aleatorias toman un número **finito** de valores. Esto es lo habitual en RL tabular y permite escribir sumas en lugar de integrales sin perder nada esencial.

Parte I: Probabilidad elemental

2. Variables aleatorias y sucesiones estocásticas

Definición 2.1 (Variable aleatoria, versión informal). Una *variable aleatoria* es una cantidad que puede tomar valores de un conjunto de números, y el valor que toma sigue una distribución de probabilidad.

La palabra «variable» indica que puede tomar varios valores; «aleatoria» indica que hacerlo obedece a una distribución. En la Parte II veremos que, en rigor, una variable aleatoria *es una función*.

Definición 2.2 (Sucesión estocástica). Una *sucesión estocástica* es una sucesión de variables aleatorias $\{X_k\} = \{X_1, X_2, \dots\}$.

Ejemplo 2.3 (Un punto que confunde a los principiantes). Lanzamos un dado n veces y llamamos x_i al resultado del lanzamiento i -ésimo. ¿Es $\{x_1, \dots, x_n\}$ una sucesión estocástica? Sí. Si escribimos $\{1, 6, 3, 5, \dots\}$ tenemos una *realización* concreta, y ahí ya no hay nada aleatorio: todos los elementos están determinados. Pero mientras x_i designe *los valores que podrían salir*, es una variable aleatoria, **aunque se escriba en minúscula**.

Conexión con RL. Un episodio observado $s_0, a_0, r_1, s_1, \dots$ es una realización. La trayectoria como objeto matemático $S_0, A_0, R_1, S_1, \dots$ es una sucesión estocástica. Los algoritmos de Monte Carlo usan realizaciones para estimar cantidades definidas sobre la sucesión estocástica.

3. Probabilidad conjunta, condicional e independencia

3.1. Definiciones básicas

- **Probabilidad marginal:** $p(x) = \mathbb{P}(X = x)$.
- **Probabilidad conjunta:** $p(x, y) = \mathbb{P}(X = x, Y = y)$. Se cumple la identidad de *marginalización*

$$\sum_y p(x, y) = p(x).$$

- **Probabilidad condicional:** $p(x|a)$ es la probabilidad de que $X = x$ sabiendo que $A = a$. Se cumple

$$p(x, a) = p(x|a)p(a), \quad p(x|a) = \frac{p(x, a)}{p(a)} \quad (p(a) > 0).$$

Definición 3.1 (Independencia). X e Y son *independientes* si $p(x, y) = p(x)p(y)$ para todo x, y ; equivalentemente, si $p(x|y) = p(x)$. Intuitivamente: la independencia nos dice que observar una variable no cambia nuestra creencia sobre la otra.

Definición 3.2 (Independencia condicional). X es *condicionalmente independiente* de A dado B si

$$p(x|a, b) = p(x|b).$$

Es decir: una vez que conocemos B , saber además A no aporta información sobre X .

Conexión con RL (La propiedad de Markov). Consideremos tres estados consecutivos s_t, s_{t+1}, s_{t+2} . En general s_{t+2} depende tanto de s_{t+1} como de s_t . Pero si s_{t+1} ya está dado, entonces s_{t+2} es condicionalmente independiente de s_t :

$$p(s_{t+2}|s_{t+1}, s_t) = p(s_{t+2}|s_{t+1}).$$

Ésta es exactamente la **propiedad de ausencia de memoria** de los procesos de Markov, y es la hipótesis que hace que todo el aparato de los MDP funcione.

3.2. Ley de la probabilidad total y regla de la cadena

Propiedad 3.3 (Ley de la probabilidad total).

$$p(x) = \sum_y p(x, y) = \sum_a p(x|a) p(a), \quad y \text{ también} \quad p(x|a) = \sum_y p(x, y|a).$$

Propiedad 3.4 (Regla de la cadena). De $p(a, b) = p(a|b)p(b)$ se obtiene, encadenando,

$$p(a, b, c) = p(a|b, c) p(b|c) p(c),$$

y dividiendo por $p(c)$,

$$p(a, b|c) = p(a|b, c) p(b|c).$$

Como consecuencia inmediata,

$$p(x|a) = \sum_b p(x, b|a) = \sum_b p(x|b, a) p(b|a). \quad (1)$$

Conexión con RL. La ecuación (1) es la que permite escribir la dinámica de un estado bajo una política marginalizando sobre las acciones:

$$p_\pi(s'|s) = \sum_a p(s'|s, a) \pi(a|s).$$

4. Esperanza

Definición 4.1 (Esperanza). Si X toma el valor x con probabilidad $p(x)$,

$$\mathbb{E}[X] \stackrel{\text{def}}{=} \sum_x p(x) x.$$

También se llama *valor esperado* o *media*.

4.1. Linealidad

Propiedad 4.2 (Linealidad).

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \quad \mathbb{E}[aX] = a \mathbb{E}[X].$$

Idea de la demostración. La segunda igualdad es inmediata. Para la primera, se escribe la

esperanza sobre la distribución conjunta y se marginaliza:

$$\mathbb{E}[X + Y] = \sum_x \sum_y (x + y) p(x, y) = \sum_x x \underbrace{\sum_y p(x, y)}_{=p(x)} + \sum_y y \underbrace{\sum_x p(x, y)}_{=p(y)} = \mathbb{E}[X] + \mathbb{E}[Y].$$

□

Observación (Importante). La linealidad **no requiere independencia**. Ésta es la razón por la que es una herramienta tan poderosa: podemos partir el retorno $G_t = R_{t+1} + \gamma G_{t+1}$ en trozos fuertemente correlacionados y tomar esperanzas sin preocuparnos.

De la linealidad se siguen, por inducción,

$$\mathbb{E}\left[\sum_i a_i X_i\right] = \sum_i a_i \mathbb{E}[X_i], \quad \mathbb{E}[AX] = A \mathbb{E}[X],$$

donde $A \in \mathbb{R}^{n \times n}$ es una matriz determinista y $X \in \mathbb{R}^n$ un vector aleatorio. Esta última identidad es la que justifica la forma matricial de la ecuación de Bellman, $v_\pi = r_\pi + \gamma P_\pi v_\pi$.

4.2. Esperanza condicional y ley de la esperanza total

Definición 4.3 (Esperanza condicional).

$$\mathbb{E}[X|A = a] \stackrel{\text{def}}{=} \sum_x x p(x|a).$$

Propiedad 4.4 (Ley de la esperanza total).

$$\mathbb{E}[X] = \sum_a \mathbb{E}[X|A = a] p(a). \quad (2)$$

Demostración.

$$\sum_a \mathbb{E}[X|A = a] p(a) = \sum_a \left[\sum_x x p(x|a) \right] p(a) = \sum_x x \sum_a \underbrace{p(x|a)p(a)}_{=p(x,a)} = \sum_x x p(x) = \mathbb{E}[X]. \quad \square$$

Análogamente, condicionando una vez más:

$$\mathbb{E}[X|A = a] = \sum_b \mathbb{E}[X|A = a, B = b] p(b|a). \quad (3)$$

(La pista de la demostración es la regla de la cadena $p(x|a, b)p(b|a) = p(x, b|a)$.)

Conexión con RL. La ley de la esperanza total (2) y su versión condicional (3) son el motor de la derivación de la ecuación de Bellman. Se usa (3) para reescribir $\mathbb{E}[G_t|S_t = s]$ condicionando sobre la acción $A_t = a$, y después sobre el estado siguiente $S_{t+1} = s'$. El Ejercicio 8 recorre esa derivación paso a paso.

Cuidado. $\mathbb{E}[X|A = a]$ es un **número**. $\mathbb{E}[X|A]$ es una **variable aleatoria**: es una función de A , y como A es aleatoria, el resultado también lo es. Definir esto con rigor requiere teoría de la medida; lo haremos en la Sección 9.

4.3. Gradiente de una esperanza

Propiedad 4.5. Sea $f(X, \beta)$ una función escalar de una variable aleatoria X y de un vector de parámetros deterministas β . Entonces

$$\nabla_{\beta} \mathbb{E}[f(X, \beta)] = \mathbb{E}[\nabla_{\beta} f(X, \beta)].$$

Demostración. $\nabla_{\beta} \sum_x f(x, \beta) p(x) = \sum_x \nabla_{\beta} f(x, \beta) p(x)$, ya que $p(x)$ no depende de β . $\square$

Observación. La demostración usa de forma esencial que $p(x)$ **no depende de** β . En el método de gradiente de política eso *no* se cumple: la distribución depende del parámetro θ de la política. Por eso allí hace falta el *truco del logaritmo* (véase el Ejercicio 9).

4.4. Varianza y covarianza

Definición 4.6. Sea $\bar{x} = \mathbb{E}[X]$ y $\bar{y} = \mathbb{E}[Y]$. Se define

$$\text{var}(X) \stackrel{\text{def}}{=} \mathbb{E}[(X - \bar{x})^2], \quad \text{cov}(X, Y) \stackrel{\text{def}}{=} \mathbb{E}[(X - \bar{x})(Y - \bar{y})].$$

Para un vector aleatorio $X = [X_1, \dots, X_n]^T$, la *matriz de covarianza* es

$$\text{var}(X) \stackrel{\text{def}}{=} \Sigma = \mathbb{E}[(X - \bar{x})(X - \bar{x})^T] \in \mathbb{R}^{n \times n}, \quad [\Sigma]_{ij} = \text{cov}(X_i, X_j).$$

Hechos útiles:

- $\text{var}(a) = 0$ si a es determinista.
- $\text{var}(AX + a) = \text{var}(AX) = A \text{var}(X) A^T = A \Sigma A^T$.
- $\mathbb{E}[(X - \bar{x})(Y - \bar{y})] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.
- Si X e Y son independientes, $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ y por tanto $\text{cov}(X, Y) = 0$.

Conexión con RL. La varianza no es un detalle decorativo. La diferencia práctica entre Monte Carlo y TD es un compromiso *sesgo-varianza*; los métodos *actor-critic* con *baseline* explotan que el gradiente de política es invariante ante ciertas constantes para **reducir la varianza** del estimador sin introducir sesgo.

Parte II: Probabilidad con teoría de la medida

5. ¿Por qué hace falta más rigor?

¿es necesario entender la probabilidad basada en teoría de la medida antes de estudiar RL? La respuesta es **sí, si uno quiere analizar rigurosamente la convergencia de sucesiones estocásticas**. La noción de *convergencia casi segura* que aparece en los Capítulos 6 y 7 (RM, Dvoretzky, Q-learning) procede de ahí. Si no interesa la convergencia, esta parte puede omitirse.

Hay además una razón conceptual: la expresión $\mathbb{E}[X|Y]$, entendida como *variable aleatoria*, no se puede definir bien con las herramientas de la Parte I.

6. La tripleta de probabilidad

Definición 6.1 (Tripleta de probabilidad). Una *tripleta de probabilidad* (o *espacio de probabilidad*) es $(\Omega, \mathcal{F}, \mathbb{P})$, donde:

- Ω es el **espacio muestral**: el conjunto de todos los resultados posibles. A cada elemento $\omega \in \Omega$ se le llama *resultado* (*outcome*).
- $\mathcal{F}$ es una **σ -álgebra** sobre Ω : una colección de subconjuntos de Ω (los *eventos*).
- $\mathbb{P}$ es una **medida de probabilidad** que asigna a cada evento de $\mathcal{F}$ un número en $[0, 1]$, con $\mathbb{P}(\Omega) = 1$.

Definición 6.2 (σ -álgebra). $\mathcal{F}$ es una σ -álgebra si

- (a) $\emptyset \in \mathcal{F}$ y $\Omega \in \mathcal{F}$;
- (b) es cerrada bajo complementos: si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
- (c) es cerrada bajo uniones numerables: si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_i A_i \in \mathcal{F}$.

Observación. Las tres condiciones no son independientes: si $\mathcal{F}$ contiene Ω y es cerrada bajo complementos, contiene $\emptyset$ automáticamente. Además, la σ -álgebra asociada a un Ω dado **no es única**.

Ejemplo 6.3 (El dado). Con $\Omega = \{1, 2, 3, 4, 5, 6\}$, la colección $\mathcal{F} = \{\Omega, \emptyset, \{1, 2, 3\}, \{4, 5, 6\}\}$ es una σ -álgebra. También lo es $\{\Omega, \emptyset, \{1, 2, 3, 4, 5\}, \{6\}\}$. Y para cualquier Ω finito, la colección de *todos* los subconjuntos de Ω es una σ -álgebra.

Observación (Intuición). Conviene leer una σ -álgebra como «la información disponible»: el conjunto de preguntas de tipo sí/no que podemos responder. Con $\mathcal{F} = \{\Omega, \emptyset, \{1, 2, 3\}, \{4, 5, 6\}\}$ sólo podemos saber si el dado salió bajo o alto, no el número exacto. Esta lectura es la que hace natural, más adelante, la idea de condicionar sobre la historia H_k de un algoritmo.

7. Variables aleatorias (formalmente)

Se llaman *variables*, pero en realidad son **funciones** que van de Ω a $\mathbb{R}$: asignan un valor numérico a cada resultado.

Definición 7.1 (Variable aleatoria). Una función $X : \Omega \rightarrow \mathbb{R}$ es una *variable aleatoria* si

$$A = \{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F} \quad \text{para todo } x \in \mathbb{R}.$$

Es decir: X es variable aleatoria sólo si « $X(\omega) \leq x$ » es un *evento* de $\mathcal{F}$ (algo a lo que $\mathbb{P}$ sabe asignar probabilidad). No toda función de Ω en $\mathbb{R}$ cumple esto: depende de qué σ -álgebra hayamos fijado.

8. Funciones indicadoras y esperanza de variables simples

Definición 8.1 (Variable aleatoria simple). X es *simple* si $X(\omega)$ toma sólo un número finito de valores. Sea $\mathcal{X}$ el conjunto de esos valores. Entonces X puede escribirse en forma cerrada como

$$X(\omega) \stackrel{\text{def}}{=} \sum_{x \in \mathcal{X}} x \mathbf{1}_{A_x}(\omega), \quad A_x = \{\omega \in \Omega : X(\omega) = x\} = X^{-1}(x),$$

donde la *función indicadora* es

$$\mathbf{1}_{A_x}(\omega) \stackrel{\text{def}}{=} \begin{cases} 1, & \omega \in A_x, \\ 0, & \text{en otro caso.} \end{cases}$$

Es posible que varios ω se apliquen al mismo valor x , pero un solo ω nunca puede aplicarse a dos valores distintos (es una función).

Definición 8.2 (Esperanza de una variable simple).

$$\mathbb{E}[X] \stackrel{\text{def}}{=} \sum_{x \in \mathcal{X}} x \mathbb{P}(A_x), \quad A_x = \{\omega \in \Omega : X(\omega) = x\}. \quad (4)$$

Compárese con la versión elemental $\mathbb{E}[X] = \sum_{x \in \mathcal{X}} x p(x)$: es la misma idea, sólo que ahora « $p(x)$ » se identifica explícitamente con la medida del conjunto de resultados que producen el valor x .

Ejemplo 8.3 (La esperanza de una indicadora). La propia función indicadora es una variable aleatoria (de Ω en $\{0, 1\}$), así que podemos calcular su esperanza. Para cualquier evento A :

$$\mathbb{E}[\mathbf{1}_A] = \sum_{z \in \{0,1\}} z \mathbb{P}(\mathbf{1}_A = z) = 0 \cdot \mathbb{P}(\mathbf{1}_A = 0) + 1 \cdot \mathbb{P}(\mathbf{1}_A = 1) = \mathbb{P}(A).$$

Observación. La identidad $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$ es el puente entre «contar probabilidades» y «promediar». Es la razón por la que casi cualquier enunciado probabilístico puede reescribirse como un enunciado sobre esperanzas, y por tanto atacarse con métodos de estimación de medias, que es justo lo que hacen los algoritmos de RL!

9. La esperanza condicional como variable aleatoria

Mientras que la esperanza (4) lleva variables aleatorias a *números*, la esperanza condicional puede llevar variables aleatorias a *otras variables aleatorias*. Distingamos tres casos, con X, Y, Z variables aleatorias:

- (1) $\mathbb{E}[X|Y = 2]$ o $\mathbb{E}[X|Y = 5]$ es un **número** concreto.
- (2) $\mathbb{E}[X|Y = y]$, con y variable, es una **función de y** .
- (3) $\mathbb{E}[X|Y]$, con Y aleatoria, es una función de Y y por tanto **una variable aleatoria**.

El tercer caso es el que aparece sin cesar en los análisis de convergencia. Como $\mathbb{E}[X|Y]$ es una variable aleatoria, tiene sentido calcular, por ejemplo, su esperanza. La definición rigurosa requiere teoría de la medida; nos limitamos a las propiedades útiles.

Lema 9.1 (Propiedades básicas). *Sean X, Y, Z variables aleatorias y a, b números dados. Entonces:*

- (a) $\mathbb{E}[a|Y] = a$.
- (b) $\mathbb{E}[aX + bZ|Y] = a \mathbb{E}[X|Y] + b \mathbb{E}[Z|Y]$.
- (c) $\mathbb{E}[X|Y] = \mathbb{E}[X]$ si X e Y son independientes.
- (d) $\mathbb{E}[Xf(Y)|Y] = f(Y) \mathbb{E}[X|Y]$.
- (e) $\mathbb{E}[f(Y)|Y] = f(Y)$.
- (f) $\mathbb{E}[X|Y, f(Y)] = \mathbb{E}[X|Y]$.
- (g) Si $X \geq 0$, entonces $\mathbb{E}[X|Y] \geq 0$.
- (h) Si $X \geq Z$, entonces $\mathbb{E}[X|Y] \geq \mathbb{E}[Z|Y]$.

Demostración de (d), a modo de ilustración. Basta comprobar que

$$\mathbb{E}[Xf(Y)|Y = y] = f(y) \mathbb{E}[X|Y = y]$$

para todo y :

$$\mathbb{E}[Xf(Y)|Y = y] = \sum_x x f(y) p(x|y) = f(y) \sum_x x p(x|y) = f(y) \mathbb{E}[X|Y = y]. \quad \square$$

Observación (La lectura intuitiva). Las propiedades (d) y (e) dicen lo mismo desde dos ángulos: **si algo ya está determinado por lo que estamos condicionando, sale fuera de la esperanza como si fuera una constante**. Ésta es la propiedad que se usa una y otra vez en la demostración del teorema de Dvoretzky, cuando Δ_k (al estar contenido en la historia H_k) se extrae de $\mathbb{E}[\cdot|H_k]$.

Lema 9.2 (Propiedad de la torre). Sean X, Y, Z variables aleatorias. Entonces:

- (a) $\mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[X]$.
- (b) $\mathbb{E}[\mathbb{E}[X|Y, Z]] = \mathbb{E}[X]$.
- (c) $\mathbb{E}[\mathbb{E}[X|Y] | Y] = \mathbb{E}[X|Y]$.

Demostración de (a). Como $\mathbb{E}[X|Y]$ es función de Y , la denotamos $f(Y) = \mathbb{E}[X|Y]$. Entonces

$$\begin{aligned} \mathbb{E}[\mathbb{E}[X|Y]] &= \mathbb{E}[f(Y)] = \sum_y f(y) p(y) = \sum_y \left(\sum_x x p(x|y) \right) p(y) = \sum_x x \sum_y p(x, y) = \\ &= \sum_x x p(x) = \mathbb{E}[X]. \end{aligned}$$

La parte (c) se sigue de inmediato de la propiedad (e) del Lema 9.1, porque $\mathbb{E}[X|Y]$ es una función de Y . $\square$

Conexión con RL. El Lema 9.2(a) es la versión «variable aleatoria» de la ley de la esperanza total. En la práctica dice: **promediar por etapas da el mismo resultado que promediar de golpe**. Es lo que permite escribir $v_\pi(s) = \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s]$ sin desarrollar la serie infinita del retorno, y lo que hace que el objetivo *bootstrap* de TD sea insesgado respecto de la esperanza correcta.

10. Modos de convergencia estocástica

Consideremos una sucesión estocástica $\{X_k\} = \{X_1, X_2, \dots\}$, donde cada elemento es una variable aleatoria definida sobre la misma tripleta $(\Omega, \mathcal{F}, \mathbb{P})$. Decir que « $\{X_k\}$ converge a X » es ambiguo: hay varios sentidos posibles.

Definición 10.1 (Convergencia segura). $\{X_k\}$ converge *seguramente* (o *puntualmente*) a X si

$$\lim_{k \rightarrow \infty} X_k(\omega) = X(\omega) \quad \text{para todo } \omega \in \Omega,$$

equivalentemente, si $A = \Omega$ donde $A = \{\omega \in \Omega : \lim_{k \rightarrow \infty} X_k(\omega) = X(\omega)\}$.

Definición 10.2 (Convergencia casi segura). $\{X_k\}$ converge *casi seguramente* (o *con probabilidad 1*) a X si

$$\mathbb{P}(A) = 1 \quad \text{donde} \quad A = \left\{ \omega \in \Omega : \lim_{k \rightarrow \infty} X_k(\omega) = X(\omega) \right\}. \quad (5)$$

El límite vale para *casi todos* los puntos de Ω : los puntos donde falla forman un conjunto de medida nula. Se escribe abreviadamente $\mathbb{P}(\lim_{k \rightarrow \infty} X_k = X) = 1$, o bien $X_k \xrightarrow{\text{c.s.}} X$.

Definición 10.3 (Convergencia en probabilidad). $\{X_k\}$ converge *en probabilidad* a X si para todo $\epsilon > 0$

$$\lim_{k \rightarrow \infty} \mathbb{P}(A_k) = 0 \quad \text{donde} \quad A_k = \{\omega \in \Omega : |X_k(\omega) - X(\omega)| > \epsilon\},$$

lo que se escribe $\lim_{k \rightarrow \infty} \mathbb{P}(|X_k - X| > \epsilon) = 0$.

Cuidado. Tanto la convergencia segura como la casi segura **primero** evalúan si hay convergencia en cada punto de Ω y **después** miden el conjunto de puntos donde la hay. La convergencia en probabilidad hace lo contrario: **primero** identifica, para cada k , los puntos donde $|X_k - X| > \epsilon$ y **después** comprueba si esa medida tiende a cero. De ahí que sea más débil: permite que ningún ω concreto converja, siempre que el «conjunto malo» vaya encogiéndose.

Definición 10.4 (Convergencia en media de orden r). $\{X_k\}$ converge *en media r -ésima* (o en norma L^r) a X si

$$\lim_{k \rightarrow \infty} \mathbb{E}[|X_k - X|^r] = 0.$$

Los casos más usados son $r = 1$ y $r = 2$.

Cuidado. La convergencia en media **no** equivale a $\lim_k \mathbb{E}[X_k - X] = 0$ ni a $\lim_k \mathbb{E}[X_k] = \mathbb{E}[X]$. Estas últimas dicen que la media converge, pero la varianza podría no hacerlo.

Definición 10.5 (Convergencia en distribución). $\{X_k\}$ converge *en distribución* a X si las funciones de distribución acumulada convergen:

$$\lim_{k \rightarrow \infty} \mathbb{P}(X_k \leq a) = \mathbb{P}(X \leq a) \quad \text{para todo } a \in \mathbb{R}.$$

10.1. Relaciones entre los modos

convergencia casi segura $\Rightarrow$ convergencia en probabilidad $\Rightarrow$ convergencia en distribución
 convergencia en media $\Rightarrow$ convergencia en probabilidad $\Rightarrow$ convergencia en distribución

La convergencia casi segura y la convergencia en media **no se implican mutuamente**. Ninguna de las implicaciones anteriores es reversible.

Conexión con RL (Dónde aparece esto). Los teoremas de convergencia centrales de RL se enuncian en el sentido *casi seguro*. Por ejemplo, el algoritmo de estimación de la media

$$w_{k+1} = w_k + \alpha_k(x_k - w_k)$$

converge a $\mathbb{E}[X]$ casi seguramente si $\{x_k\}$ es i.i.d. y

$$\sum_{k=1}^{\infty} \alpha_k = \infty, \quad \sum_{k=1}^{\infty} \alpha_k^2 < \infty.$$

La primera condición exige que los pasos no se hagan pequeños *demasiado rápido* (si no, el algoritmo se congela antes de llegar); la segunda exige que *sí* se hagan pequeños (si no, el ruido nunca se promedia). Notablemente, la convergencia no depende de ninguna hipótesis sobre la distribución de X . El mismo esquema, vía el teorema de Robbins–Monro y el de Dvoretzky, sostiene la convergencia de TD y Q-learning.

11. Resumen de fórmulas clave

Concepto	Expresión
Regla de la cadena	$p(a, b, c) = p(a b, c)p(b c)p(c)$
Probabilidad total	$p(x) = \sum_a p(x a)p(a)$
Markov	$p(s_{t+2} s_{t+1}, s_t) = p(s_{t+2} s_{t+1})$
Linealidad	$\mathbb{E}[\sum_i a_i X_i] = \sum_i a_i \mathbb{E}[X_i]$
Esperanza total	$\mathbb{E}[X] = \sum_a \mathbb{E}[X A = a] p(a)$
Torre	$\mathbb{E}[\mathbb{E}[X Y]] = \mathbb{E}[X]$
«Sacar lo conocido»	$\mathbb{E}[Xf(Y) Y] = f(Y)\mathbb{E}[X Y]$
Indicadora	$\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$
Gradiente	$\nabla_\beta \mathbb{E}[f(X, \beta)] = \mathbb{E}[\nabla_\beta f(X, \beta)]$
Varianza	$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$
Forma matricial	$\text{var}(AX + a) = A \Sigma A^\top$
Condiciones de paso	$\sum_k \alpha_k = \infty, \sum_k \alpha_k^2 < \infty$

12. Ejercicios

Cada ejercicio incluye una *pista*. Las soluciones completas están en la Sección 13. Se recomienda encarecidamente intentar el ejercicio antes de leer la pista, y la pista antes de leer la solución.

Ejercicio 1 (σ -álgebras y medibilidad). Sea $\Omega = \{1, 2, 3, 4, 5, 6\}$ (el dado).

- Verifique que $\mathcal{F}_1 = \{\Omega, \emptyset, \{1, 2, 3\}, \{4, 5, 6\}\}$ es una σ -álgebra.
- ¿Es $\mathcal{F}_2 = \{\Omega, \emptyset, \{1, 2, 3\}, \{4, 5\}, \{6\}\}$ una σ -álgebra?
- Sea $X(\omega) = \omega$ (el número que sale). ¿Es X una variable aleatoria respecto de $\mathcal{F}_1$? ¿Y respecto de la σ -álgebra de *todos* los subconjuntos de Ω ?
- Encuentre una función $Y : \Omega \rightarrow \mathbb{R}$ no constante que *sí* sea variable aleatoria respecto de $\mathcal{F}_1$.

Pista: para (c) y (d), escriba explícitamente el conjunto $\{\omega : X(\omega) \leq x\}$ para varios valores de x y compruebe si pertenece a $\mathcal{F}_1$.

Ejercicio 2 (Linealidad generalizada). Demuestre por inducción que $\mathbb{E}[\sum_{i=1}^n a_i X_i] = \sum_{i=1}^n a_i \mathbb{E}[X_i]$ para constantes a_i y variables aleatorias X_i cualesquiera. ¿Dónde se usa la independencia?

Pista: en ninguna parte. Ése es justamente el punto del ejercicio; asegúrese de entender por qué la demostración funciona sin ella.

Ejercicio 3 (Varianza). Demuestre que $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ y, más generalmente, que $\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

Pista: desarrolle $(X - \bar{x})(Y - \bar{y})$ y aplique linealidad, recordando que $\bar{x}$ y $\bar{y}$ son *números*, no variables aleatorias.

Ejercicio 4 (Covarianza nula no implica independencia). Sea X uniforme sobre $\{-1, 0, 1\}$ y sea $Y = X^2$.

- (a) Calcule $\text{cov}(X, Y)$.
- (b) ¿Son X e Y independientes?

Pista: para (b), compare $p(X = 0|Y = 0)$ con $p(X = 0)$.

Ejercicio 5 (La indicadora). Sea A un evento con $\mathbb{P}(A) = q$.

- (a) Demuestre que $\mathbb{E}[\mathbf{1}_A] = q$.
- (b) Calcule $\text{var}(\mathbf{1}_A)$ y determine para qué valor de q es máxima.
- (c) Demuestre que $\mathbf{1}_{A \cap B} = \mathbf{1}_A \mathbf{1}_B$ y deduzca que $\mathbb{E}[\mathbf{1}_A \mathbf{1}_B] = \mathbb{P}(A \cap B)$.

Pista: para (b), observe que $\mathbf{1}_A^2 = \mathbf{1}_A$ porque $0^2 = 0$ y $1^2 = 1$.

Ejercicio 6 (Sacar lo conocido fuera de la esperanza). Sean S_t, S_{t+1} estados de un proceso de Markov y sea $v : \mathcal{S} \rightarrow \mathbb{R}$ una función determinista.

- (a) Justifique, usando el Lema 9.1, que $\mathbb{E}[v(S_t) | S_t] = v(S_t)$.
- (b) Justifique que $\mathbb{E}[v(S_t) G_{t+1} | S_t] = v(S_t) \mathbb{E}[G_{t+1} | S_t]$.
- (c) En la demostración del teorema de Dvoretzky se escribe $\mathbb{E}[-\alpha_k(2 - \alpha_k)\Delta_k^2 | H_k] = -\alpha_k(2 - \alpha_k)\Delta_k^2$ cuando α_k y Δ_k están determinados por H_k . ¿Qué propiedad se está usando?

Pista: todo el ejercicio gira en torno a las propiedades (d) y (e) del Lema 9.1.

Ejercicio 7 (La torre, numéricamente). Sean $X \in \{0, 1\}$ e $Y \in \{a, b\}$ con distribución conjunta

$$p(X = 1, Y = a) = 0.2, \quad p(X = 0, Y = a) = 0.3, \quad p(X = 1, Y = b) = 0.4, \quad p(X = 0, Y = b) = 0.1.$$

- (a) Calcule $\mathbb{E}[X|Y = a]$ y $\mathbb{E}[X|Y = b]$.
- (b) Describa $\mathbb{E}[X|Y]$ como variable aleatoria: ¿qué valores toma y con qué probabilidades?
- (c) Verifique numéricamente que $\mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[X]$.

Pista: primero marginalice para obtener $p(Y = a)$ y $p(Y = b)$.

Ejercicio 8 (Derivación de la ecuación de Bellman). Sea $G_t = R_{t+1} + \gamma G_{t+1}$ y $v_\pi(s) = \mathbb{E}[G_t | S_t = s]$. Usando la linealidad y la ley de la esperanza total, demuestre que

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r r p(r|s, a) + \gamma \sum_{s'} p(s'|s, a) v_\pi(s') \right].$$

Pista: separe en dos términos, $\mathbb{E}[R_{t+1} | S_t = s]$ y $\gamma \mathbb{E}[G_{t+1} | S_t = s]$. Para el primero, condicione sobre $A_t = a$ usando (3). Para el segundo, condicione sobre $S_{t+1} = s'$ y aplique la propiedad de Markov para argumentar que $\mathbb{E}[G_{t+1} | S_{t+1} = s', S_t = s] = \mathbb{E}[G_{t+1} | S_{t+1} = s'] = v_\pi(s')$.

Ejercicio 9 (El truco del logaritmo). Sea $X \sim p_\theta$ una variable aleatoria cuya distribución depende de un parámetro θ , y sea f una función que *no* depende de θ .

- (a) Explique por qué **no** es válido escribir $\nabla_\theta \mathbb{E}_{X \sim p_\theta}[f(X)] = \mathbb{E}[\nabla_\theta f(X)]$.
- (b) Demuestre que $\nabla_\theta \mathbb{E}_{X \sim p_\theta}[f(X)] = \mathbb{E}_{X \sim p_\theta}[f(X) \nabla_\theta \ln p_\theta(X)]$.

Pista: escriba la esperanza como suma, derive, y multiplique y divida por $p_\theta(x)$ usando $\nabla_\theta \ln p_\theta(x) = \nabla_\theta p_\theta(x) / p_\theta(x)$.

Ejercicio 10 (Condiciones de tamaño de paso). Determine cuáles de las siguientes sucesiones satisfacen $\sum_k \alpha_k = \infty$ y $\sum_k \alpha_k^2 < \infty$ simultáneamente:

- (a) $\alpha_k = \frac{1}{k}$, (b) $\alpha_k = \frac{1}{\sqrt{k}}$, (c) $\alpha_k = \frac{1}{k^2}$, (d) $\alpha_k = \alpha$ constante.

Interprete el resultado: ¿qué le ocurre a un algoritmo con paso constante?

Pista: recuerde que $\sum_k k^{-p}$ converge si y sólo si $p > 1$.

Ejercicio 11 (En probabilidad pero no en media). Sea $\{X_k\}$ con

$$X_k = \begin{cases} k, & \text{con probabilidad } 1/k, \\ 0, & \text{con probabilidad } 1 - 1/k. \end{cases}$$

- (a) ¿Converge $\{X_k\}$ a 0 en probabilidad?
- (b) ¿Converge en media ($r = 1$)?
- (c) ¿Qué muestra esto sobre la relación entre ambos modos?

Pista: para (a) fije $\epsilon > 0$ y calcule $\mathbb{P}(|X_k| > \epsilon)$ para k grande. Para (b) calcule $\mathbb{E}[|X_k|]$.

Ejercicio 12 (En probabilidad pero no casi seguramente). Sea $\Omega = [0, 1]$ con la medida de Lebesgue (probabilidad uniforme). Para cada $k \geq 1$ escriba $k = 2^n + j$ con $0 \leq j < 2^n$, y defina

$$X_k(\omega) = \mathbf{1}_{[j/2^n, (j+1)/2^n)}(\omega).$$

- (a) Demuestre que $X_k \rightarrow 0$ en probabilidad.
- (b) Demuestre que X_k **no** converge a 0 casi seguramente. De hecho, no converge en *ningún* punto ω .
- (c) Concluya qué implicación entre modos de convergencia queda descartada.

Pista: en (a) note que el intervalo indicador tiene longitud $2^{-n} \rightarrow 0$. En (b) fije un ω cualquiera y observe que, para cada n , existe exactamente un j tal que ω cae en el intervalo correspondiente, de modo que la sucesión $X_k(\omega)$ vale 1 infinitas veces y 0 infinitas veces.

13. Soluciones

Solución 1.

- (a) Contiene Ω y $\emptyset$. Complementos: $\{1, 2, 3\}^c = \{4, 5, 6\} \in \mathcal{F}_1$, $\Omega^c = \emptyset \in \mathcal{F}_1$. Uniones: $\{1, 2, 3\} \cup \{4, 5, 6\} = \Omega \in \mathcal{F}_1$, y cualquier unión con $\emptyset$ o Ω es trivial. Es σ -álgebra.
- (b) No. Falla el cierre bajo uniones: $\{4, 5\} \cup \{6\} = \{4, 5, 6\} \notin \mathcal{F}_2$. (También falla el complemento: $\{1, 2, 3\}^c = \{4, 5, 6\} \notin \mathcal{F}_2$.)
- (c) Respecto de $\mathcal{F}_1$, **no**: tomando $x = 1$ obtenemos $\{\omega : X(\omega) \leq 1\} = \{1\}$, que no pertenece a $\mathcal{F}_1$. Intuitivamente, $\mathcal{F}_1$ sólo «sabe» distinguir bajo de alto, no el número exacto. Respecto de la σ -álgebra de todos los subconjuntos, **sí**: cualquier conjunto pertenece a ella por construcción.
- (d) Por ejemplo $Y(\omega) = 0$ si $\omega \in \{1, 2, 3\}$ y $Y(\omega) = 1$ si $\omega \in \{4, 5, 6\}$. Entonces $\{\omega : Y(\omega) \leq x\}$ vale $\emptyset$ (si $x < 0$), $\{1, 2, 3\}$ (si $0 \leq x < 1$) o Ω (si $x \geq 1$); los tres pertenecen a $\mathcal{F}_1$. En general, las variables aleatorias respecto de $\mathcal{F}_1$ son exactamente las funciones constantes en cada uno de los bloques $\{1, 2, 3\}$ y $\{4, 5, 6\}$.

Solución 2. Caso base $n = 1$: $\mathbb{E}[a_1 X_1] = a_1 \mathbb{E}[X_1]$ por la propiedad $\mathbb{E}[aX] = a\mathbb{E}[X]$. Paso inductivo: supongamos el resultado cierto para n . Sea $S_n = \sum_{i=1}^n a_i X_i$. Entonces

$$\mathbb{E}\left[\sum_{i=1}^{n+1} a_i X_i\right] = \mathbb{E}[S_n + a_{n+1} X_{n+1}] \stackrel{(1)}{=} \mathbb{E}[S_n] + \mathbb{E}[a_{n+1} X_{n+1}] \stackrel{(2)}{=} \sum_{i=1}^n a_i \mathbb{E}[X_i] + a_{n+1} \mathbb{E}[X_{n+1}],$$

donde (1) es $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ y (2) la hipótesis de inducción.

La independencia **no interviene en ningún paso**. La razón es que la demostración de $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ sólo usa la marginalización $\sum_y p(x, y) = p(x)$, que es válida para cualquier

distribución conjunta. Esto es lo que hace la linealidad tan valiosa en RL: las recompensas $R_{t+1}, R_{t+2}, \dots$ de una trayectoria están fuertemente correlacionadas entre sí, y sin embargo $\mathbb{E}[G_t] = \sum_{k \geq 0} \gamma^k \mathbb{E}[R_{t+k+1}]$ sigue siendo cierto. (Contrástese con $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$, que *sí* requiere independencia.)

Solución 3. Con $\bar{x} = \mathbb{E}[X]$ y $\bar{y} = \mathbb{E}[Y]$ números:

$$\mathbb{E}[(X - \bar{x})(Y - \bar{y})] = \mathbb{E}[XY - X\bar{y} - \bar{x}Y + \bar{x}\bar{y}] = \mathbb{E}[XY] - \mathbb{E}[X]\bar{y} - \bar{x}\mathbb{E}[Y] + \bar{x}\bar{y}.$$

Sustituyendo $\bar{x} = \mathbb{E}[X]$, $\bar{y} = \mathbb{E}[Y]$:

$$= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

El caso $Y = X$ da $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

Solución 4.

- (a) $\mathbb{E}[X] = \frac{1}{3}(-1 + 0 + 1) = 0$. Además $XY = X \cdot X^2 = X^3$ y $\mathbb{E}[X^3] = \frac{1}{3}(-1 + 0 + 1) = 0$. Por tanto $\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0 - 0 \cdot \mathbb{E}[Y] = 0$.
- (b) No son independientes. Tenemos $p(X = 0) = 1/3$, mientras que $Y = 0$ ocurre exactamente cuando $X = 0$, luego $p(X = 0|Y = 0) = 1 \neq 1/3$. De hecho Y es una función determinista de X : conocer Y determina $|X|$ por completo.

Moraleja: la covarianza sólo detecta dependencia *lineal*. Es un recordatorio útil en RL, donde «desacorrelacionado» y «independiente» se confunden a menudo, por ejemplo al hablar de las muestras extraídas del *experience replay*.

Solución 5.

- (a) $\mathbb{E}[\mathbf{1}_A] = 0 \cdot \mathbb{P}(\mathbf{1}_A = 0) + 1 \cdot \mathbb{P}(\mathbf{1}_A = 1) = \mathbb{P}(\mathbf{1}_A = 1) = \mathbb{P}(A) = q$.
- (b) Como $\mathbf{1}_A$ sólo toma los valores 0 y 1, se cumple $\mathbf{1}_A^2 = \mathbf{1}_A$. Por tanto $\mathbb{E}[\mathbf{1}_A^2] = \mathbb{E}[\mathbf{1}_A] = q$ y

$$\text{var}(\mathbf{1}_A) = \mathbb{E}[\mathbf{1}_A^2] - (\mathbb{E}[\mathbf{1}_A])^2 = q - q^2 = q(1 - q).$$

Es una parábola invertida en $[0, 1]$, máxima en $q = 1/2$, con valor $1/4$. Tiene sentido: la incertidumbre es máxima cuando el evento es tan probable como improbable.

- (c) $\mathbf{1}_{A \cap B}(\omega) = 1$ si y sólo si $\omega \in A$ y $\omega \in B$, es decir si y sólo si $\mathbf{1}_A(\omega) = 1$ y $\mathbf{1}_B(\omega) = 1$, es decir si y sólo si $\mathbf{1}_A(\omega)\mathbf{1}_B(\omega) = 1$. Como ambos lados sólo toman valores en $\{0, 1\}$, son iguales. Tomando esperanzas y usando (a): $\mathbb{E}[\mathbf{1}_A\mathbf{1}_B] = \mathbb{E}[\mathbf{1}_{A \cap B}] = \mathbb{P}(A \cap B)$.

Solución 6.

- (a) Es directamente la propiedad (e) del Lema 9.1 con $f = v$ e $Y = S_t$: $\mathbb{E}[f(Y)|Y] = f(Y)$. Intuitivamente, una vez que S_t está dado, $v(S_t)$ ya no es incierto.
- (b) Es la propiedad (d) con $X = G_{t+1}$, $f = v$, $Y = S_t$: $\mathbb{E}[Xf(Y)|Y] = f(Y)\mathbb{E}[X|Y]$. El factor $v(S_t)$ es conocido dado S_t , así que sale como si fuera constante.
- (c) La misma propiedad (e)/(d). Puesto que Δ_k y α_k están contenidos en la historia H_k (o son funciones de ella), son funciones de lo que se condiciona y por tanto se extraen de la esperanza. Este paso es el que permite reducir $\mathbb{E}[h_{k+1} - h_k|H_k]$ a $-\alpha_k(2 - \alpha_k)\Delta_k^2 + \beta_k^2\mathbb{E}[\eta_k^2|H_k] + 2(1 - \alpha_k)\beta_k\Delta_k\mathbb{E}[\eta_k|H_k]$, y después, usando $\mathbb{E}[\eta_k|H_k] = 0$, a una desigualdad manejable.

Solución 7.

(a) Marginalizando: $p(Y = a) = 0.2 + 0.3 = 0.5$ y $p(Y = b) = 0.4 + 0.1 = 0.5$. Entonces

$$p(X = 1|Y = a) = \frac{0.2}{0.5} = 0.4, \quad p(X = 1|Y = b) = \frac{0.4}{0.5} = 0.8.$$

Como $X \in \{0, 1\}$, $\mathbb{E}[X|Y = y] = p(X = 1|Y = y)$, luego $\mathbb{E}[X|Y = a] = 0.4$ y $\mathbb{E}[X|Y = b] = 0.8$.

(b) $\mathbb{E}[X|Y]$ es la variable aleatoria que vale 0.4 cuando $Y = a$ y 0.8 cuando $Y = b$. Como $p(Y = a) = p(Y = b) = 0.5$, toma cada uno de esos dos valores con probabilidad 0.5. Obsérvese que es una variable aleatoria distinta de X : toma valores en $\{0.4, 0.8\}$, no en $\{0, 1\}$. Es una versión «suavizada» de X , en la que se ha promediado toda la aleatoriedad salvo la de Y .

(c) Por un lado, $\mathbb{E}[\mathbb{E}[X|Y]] = 0.4(0.5) + 0.8(0.5) = 0.2 + 0.4 = 0.6$. Por otro, $p(X = 1) = 0.2 + 0.4 = 0.6$, luego $\mathbb{E}[X] = 0.6$. Coinciden.

Solución 8. Por linealidad,

$$v_\pi(s) = \mathbb{E}[G_t|S_t = s] = \underbrace{\mathbb{E}[R_{t+1}|S_t = s]}_{(I)} + \gamma \underbrace{\mathbb{E}[G_{t+1}|S_t = s]}_{(II)}.$$

Término (I). Condicionando sobre la acción mediante (3):

$$\mathbb{E}[R_{t+1}|S_t = s] = \sum_a \mathbb{E}[R_{t+1}|S_t = s, A_t = a] \pi(a|s) = \sum_a \pi(a|s) \sum_r r p(r|s, a).$$

Término (II). Condicionando sobre el estado siguiente:

$$\mathbb{E}[G_{t+1}|S_t = s] = \sum_{s'} \mathbb{E}[G_{t+1}|S_{t+1} = s', S_t = s] p(s'|s).$$

Por la propiedad de Markov, el retorno futuro a partir de $t + 1$ depende del pasado sólo a través de S_{t+1} , de modo que

$$\mathbb{E}[G_{t+1}|S_{t+1} = s', S_t = s] = \mathbb{E}[G_{t+1}|S_{t+1} = s'] = v_\pi(s').$$

Además $p(s'|s) = \sum_a \pi(a|s)p(s'|s, a)$ por la ley de la probabilidad total. Por tanto

$$\mathbb{E}[G_{t+1}|S_t = s] = \sum_{s'} v_\pi(s') \sum_a \pi(a|s) p(s'|s, a).$$

Sumando ambos términos y agrupando por a :

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r r p(r|s, a) + \gamma \sum_{s'} p(s'|s, a) v_\pi(s') \right],$$

que es la ecuación de Bellman en forma elemental. Nótese que todo el argumento se apoya en exactamente tres herramientas: linealidad, ley de la esperanza total y propiedad de Markov.

Solución 9.

(a) Porque la demostración de $\nabla_\beta \mathbb{E}[f(X, \beta)] = \mathbb{E}[\nabla_\beta f(X, \beta)]$ requiere que $p(x)$ no dependa del parámetro: sólo así se puede pasar ∇_β dentro de la suma dejando $p(x)$ intacto. Aquí la dependencia en θ está justamente en la distribución. Además, si f no depende de θ , se tendría $\mathbb{E}[\nabla_\theta f(X)] = 0$, lo cual sería absurdo: la esperanza sí cambia con θ .

(b) Escribiendo la esperanza como suma y derivando:

$$\nabla_{\theta} \sum_x f(x) p_{\theta}(x) = \sum_x f(x) \nabla_{\theta} p_{\theta}(x) = \sum_x f(x) p_{\theta}(x) \frac{\nabla_{\theta} p_{\theta}(x)}{p_{\theta}(x)}.$$

Como $\nabla_{\theta} \ln p_{\theta}(x) = \nabla_{\theta} p_{\theta}(x) / p_{\theta}(x)$, el último término es

$$\sum_x p_{\theta}(x) f(x) \nabla_{\theta} \ln p_{\theta}(x) = \mathbb{E}_{X \sim p_{\theta}} [f(X) \nabla_{\theta} \ln p_{\theta}(X)].$$

Ésta es la identidad que convierte el gradiente de política en una esperanza *estimable por muestreo*, y por tanto la base de REINFORCE y de todos los métodos actor-critic.

Solución 10.

α_k	$\sum_k \alpha_k$	$\sum_k \alpha_k^2$	¿Cumple ambas?
$1/k$	$= \infty$ (serie armónica)	$= \pi^2/6 < \infty$	Sí
$1/\sqrt{k}$	$= \infty$	$\sum 1/k = \infty$	No
$1/k^2$	$< \infty$	$< \infty$	No
α cte	$= \infty$	$= \infty$	No

Sólo (a) cumple las dos condiciones. El criterio general: $\sum_k k^{-p}$ converge si y sólo si $p > 1$; por tanto $\alpha_k = k^{-p}$ funciona exactamente para $1/2 < p \leq 1$.

Interpretación. La condición $\sum \alpha_k^2 < \infty$ obliga a que $\alpha_k \rightarrow 0$: es lo que hace que el ruido de las muestras acabe promediándose. La condición $\sum \alpha_k = \infty$ impide que se haga cero demasiado deprisa: si los pasos se encogen demasiado rápido (caso (c)), el algoritmo se «congela» en un punto que puede estar lejos del óptimo, porque el desplazamiento total posible es finito.

Con paso constante (caso (d)), el algoritmo no converge en sentido casi seguro: sigue rebotando indefinidamente alrededor de la solución con una varianza residual proporcional a α . En la práctica, sin embargo, el paso constante es *lo habitual* en RL profundo, precisamente porque conserva la capacidad de adaptarse cuando el entorno o la política de comportamiento cambian con el tiempo. Se sacrifica convergencia asintótica a cambio de plasticidad.

Solución 11.

- (a) Sí. Fijemos $\epsilon > 0$. Para todo $k > \epsilon$ se tiene $|X_k| > \epsilon$ si y sólo si $X_k = k$, luego $\mathbb{P}(|X_k| > \epsilon) = 1/k \rightarrow 0$. Por tanto $X_k \rightarrow 0$ en probabilidad.
- (b) No. $\mathbb{E}[|X_k|] = k \cdot \frac{1}{k} + 0 \cdot (1 - \frac{1}{k}) = 1$ para todo k , de modo que $\mathbb{E}[|X_k - 0|] = 1 \not\rightarrow 0$.
- (c) Muestra que **la convergencia en probabilidad no implica la convergencia en media**. La razón es que un evento cada vez más improbable puede compensarse con un valor cada vez más grande, manteniendo la esperanza constante. En RL esto es una advertencia práctica: un estimador puede ser «casi siempre correcto» y aun así tener una media (o una varianza) que no se comporta, lo que arruina el promediado. Es exactamente el problema que aparece con los pesos de *importance sampling* cuando la política de comportamiento y la política objetivo se separan demasiado.

Solución 12. Esta construcción se conoce como la *sucesión de la máquina de escribir*: los intervalos indicadores barren $[0, 1]$ de izquierda a derecha, y cada vez que llegan al final vuelven a empezar con intervalos el doble de finos.

- (a) Para $0 < \epsilon < 1$,

$$\mathbb{P}(|X_k| > \epsilon) = \mathbb{P}(\omega \in [j/2^n, (j+1)/2^n)) = \frac{1}{2^n}.$$

Como $k = 2^n + j \geq 2^n$, se tiene $2^{-n} \leq 1/k \rightarrow 0$ cuando $k \rightarrow \infty$. Por tanto $X_k \rightarrow 0$ en probabilidad.

- (b) Fijemos cualquier $\omega \in [0, 1)$. Para cada n , los intervalos $[j/2^n, (j+1)/2^n)$ con $j = 0, \dots, 2^n - 1$ forman una partición de $[0, 1)$, así que existe exactamente un j_n con $\omega \in [j_n/2^n, (j_n+1)/2^n)$. Para el índice $k = 2^n + j_n$ se cumple $X_k(\omega) = 1$; y para cualquier otro $k' = 2^n + j$ con $j \neq j_n$ se cumple $X_{k'}(\omega) = 0$. Como esto ocurre para *todo* n , la sucesión $X_k(\omega)$ contiene infinitos unos e infinitos ceros, y por tanto no tiene límite. El conjunto donde hay convergencia es vacío (o a lo sumo $\{1\}$), cuya probabilidad es 0, no 1.
- (c) Queda descartado que la convergencia en probabilidad implique la convergencia casi segura. Junto con el Ejercicio 11, esto confirma que las flechas del diagrama de la Sección 10.1 **sólo van en un sentido**:

$$\text{c.s.} \Rightarrow \text{en probabilidad}, \quad \text{en probabilidad} \not\Rightarrow \text{c.s.}$$

Ésta es la razón por la que enunciar los teoremas de RL en el sentido casi seguro es una afirmación genuinamente más fuerte, y más difícil de demostrar, que hacerlo en probabilidad.