

Reinforcement Learning

Clase 01

Ignacio Brevis

`ignaciobrve@unisabana.edu.co`

Universidad de La Sabana

19 agosto 2026





- ignaciobrve@unisabana.edu.co
- ibrevis.github.io/
- github.com/ibrevis/RL_unisabana_2026_2



- ➊ Fundamentos Matemáticos y Modelos de RL:
- ➋ Aprendizaje Basado en Valores y Algoritmos Tabulares:
- ➌ Aprendizaje Basado en Políticas y RL Profundo:
- ➍ Algoritmos de Frontera:
- ➎ RL en el Mundo Real y Aplicaciones Avanzadas:

- ➊ **Fundamentos Matemáticos y Modelos de RL:** Introducción rigurosa al marco de los Procesos de Decisión de Markov (MDPs), la función de valor, la ecuación de Bellman y la optimización de políticas. Se cubrirán las bases teóricas necesarias para la comprensión de cualquier sistema de RL. (~ 4 clases)
- ➋ **Aprendizaje Basado en Valores y Algoritmos Tabulares:**
- ➌ **Aprendizaje Basado en Políticas y RL Profundo:**
- ➍ **Algoritmos de Frontera:**
- ➎ **RL en el Mundo Real y Aplicaciones Avanzadas:**



- ❶ **Fundamentos Matemáticos y Modelos de RL:**
- ❷ **Aprendizaje Basado en Valores y Algoritmos Tabulares:** Estudio de métodos de RL que estiman funciones de valor. Profundización en Programación Dinámica (Iteración de Políticas y Valores), métodos de Monte Carlo y Q-Learning (off-policy) y SARSA (on-policy). Énfasis en el equilibrio exploración-explotación. (~ 4 clases)
- ❸ **Aprendizaje Basado en Políticas y RL Profundo:**
- ❹ **Algoritmos de Frontera:**
- ❺ **RL en el Mundo Real y Aplicaciones Avanzadas:**

- ➊ Fundamentos Matemáticos y Modelos de RL:
- ➋ Aprendizaje Basado en Valores y Algoritmos Tabulares:
- ➌ **Aprendizaje Basado en Políticas y RL Profundo:** Transición al Aprendizaje por Refuerzo Profundo (Deep RL). Introducción a Policy Gradients (REINFORCE). Estudio detallado de Deep Q-Networks (DQN) y sus extensiones para manejar grandes espacios de estado. (~ 3 clases)
- ➍ Algoritmos de Frontera:
- ➎ RL en el Mundo Real y Aplicaciones Avanzadas:

- ➊ Fundamentos Matemáticos y Modelos de RL:
- ➋ Aprendizaje Basado en Valores y Algoritmos Tabulares:
- ➌ Aprendizaje Basado en Políticas y RL Profundo:
- ➍ **Algoritmos de Frontera:** Análisis de los algoritmos de RL más utilizados en la industria y la investigación: Proximal Policy Optimization (PPO) y Soft Actor-Critic (SAC). Se discutirán las ventajas del enfoque Actor-Critic y los problemas de eficiencia de muestreo y estabilidad de entrenamiento. (~ 2 clases)
- ➎ RL en el Mundo Real y Aplicaciones Avanzadas:

- ➊ Fundamentos Matemáticos y Modelos de RL:
- ➋ Aprendizaje Basado en Valores y Algoritmos Tabulares:
- ➌ Aprendizaje Basado en Políticas y RL Profundo:
- ➍ Algoritmos de Frontera:
- ➎ **RL en el Mundo Real y Aplicaciones Avanzadas:** Exploración de RL Multiagente (MARL), Aprendizaje por Imitación (Imitation Learning) y los desafíos de RL sin Conexión (Offline RL), necesarios para la aplicación en dominios complejos (e.g., robótica, sistemas de recomendación, optimización de recursos). Discusión sobre la robustez y la ética de los agentes autónomos. (~ 2 clases)

- Classical RL (tabular case)
 - MDP
 - Bellman equation
 - SARSA
 - Q-learning
- Deep RL (continuous case)
 - Function approximation
 - Deep Q-learning
 - Policy gradient
 - Actor-critic



- R. S. Sutton and A. G. Barto, **Reinforcement Learning: An Introduction**, 2018.
- S. Zhao, **Mathematical Foundations of Reinforcement Learning**, 2025.

Objetivo: Comprender los fundamentos del reinforcement learning.

- Comprender el origen de los algoritmos.
- Aprender a derivar los algoritmos de RL.
- Saber cuando aplicar cada método.

Obs: No es un curso de programación (ni solo de teoría)


Requisitos:

- Conocimiento sólido de **Cálculo**, **Álgebra Lineal** y **Probabilidad/Estadística** (fundamentos de **optimización** y teoría de control).
- Comprensión profunda de los fundamentos del Aprendizaje Automático (**Machine Learning**) y sus técnicas de optimización.
- Sólida experiencia en **programación (Python)** y frameworks de Deep Learning (PyTorch o TensorFlow).
- Ganas y compromiso de aprender!

Ejemplos simples:



Ejemplos más complejos:



(Lunar Lander)


Obs: Para el proyecto final, pueden usar el entorno y/o paquete que más les acomode!

- Usar modelos de LLM (o IAs en general) para clarificar, cuestionar y revisar conceptos ✓
- Usar modelos de LLM para revisar y mejorar párrafos y/o figuras ✓
- Usar modelos de LLM para generar ideas (brainstorming) ✓
- No usar IAs para que hagan el trabajo por ustedes ✗
- No confiar ciegamente en la respuesta de la IA. Siempre revisar el output (ser responsable del resultado) ✗
- Mi política: Si les pregunto cómo usaron la IA el proyecto, ¿serían capaces de contestar honestamente?

- Los estudiantes trabajarán durante el semestre en un **proyecto a elección**, aplicando las técnicas de RL aprendidas durante el semestre.
- Entrega de un informe (escrito en inglés) **tipo paper**, incluyendo: abstract, introducción, metodología, resultados, conclusiones y bibliografía (se entrega la penúltima clase).
- Códigos reproducibles y comentados (se entrega la penúltima clase).
- Presentación oral (en español) de ~ 20 min. Describiendo el problema abordado, técnicas utilizadas, resultados obtenidos, etc (última clase).
- **Se recomienda encarecidamente la participación durante el semestre.**

Importante: El informe debe estar escrito por el estudiante (no por un LLM).

Recomendación:



The screenshot shows the Coursera website interface. At the top, the Coursera logo is on the left, and navigation links for 'Explore', 'My Learning', and 'Degrees' are in the center. A search bar on the right contains the text 'What do you want to learn?'. Below the navigation bar, a breadcrumb trail shows the path: Home > Browse > Health > Basic Science. The main content area features the 'Stanford | ONLINE' logo, followed by the course title 'Writing in the Sciences' in a large, bold font. Below the title is a circular profile picture of the instructor, Dr. Kristin Sainani, with the text 'Instructor: Dr. Kristin Sainani'. A prominent blue button labeled 'Go to course' is displayed, with the text 'Already enrolled' to its right. At the bottom of the course card, it states '597,621 already enrolled'.

<https://www.coursera.org/learn/sciwrite>

Ejercicio: derivadas, minimización

Cuál es el valor de x que minimiza la función $f(x) = x^2 + 2x - 1$?

$$f(x) = x^2 + 2x - 1$$

① Calculamos su derivada

$$f'(x) = 2x + 2$$

② igualamos la derivada a cero

$$f'(x) = 2x + 2 = 0$$

$$\Rightarrow x = -1$$

Ejercicio: valor esperado

Si el participante acierta el resultado al lanzar una moneda (cara o cruz), gana \$10. Por el contrario, si falla, pierde \$2. Cuál es la ganancia promedio? (valor esperado)

Asumiendo una moneda "justa"

probabilidad de ganar \$10 = $\frac{1}{2}$

" " perder \$2 = $\frac{1}{2}$

$$\text{valor esperado} = \sum x p(x)$$

$$= 10 \cdot \frac{1}{2} + (-2) \cdot \frac{1}{2}$$

$$= 4$$

Ejercicio: probabilidad condicional


Si lanzamos dos dados consecutivamente. Cuál es la probabilidad de que la suma de los dados sea 8, dado que el primer dado salió 3. Hint: $P(A|B) = P(A \cap B)/P(B)$

A: la suma es 8

B: el primer dado es 3

$B : \{(3,1), (3,2), \dots, (3,5), (3,6)\}$
suma 8

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{1/36}{6/36} = \frac{1}{6}$$




- **Supervised learning:** Aprendizaje a partir de un set de entrenamiento etiquetado (labels).
- **Unsupervised learning:** Aprendizaje de estructuras escondidas a partir de datos sin etiquetar.
- **Reinforcement learning:** Aprendizaje mediante la interacción con un entorno y recompensas (rewards).

Introducción a reinforcement learning



<https://www.youtube.com/watch?v=spfpBrBjntg>

Introducción a reinforcement learning



Área	Ejemplos concretos
Robótica y Control	Robotic grasping and assembly; navegación de drones; locomoción cuadrúpeda; sistemas industriales de pick-and-place.
Juegos y Toma de Decisiones	AlphaGo/AlphaZero (Go, Ajedrez); agentes de Atari (DQN); StarCraft II and Dota 2 self-play systems.
Recomendación y Personalización	Ranking de videos en YouTube; compra de productos en e-commerce; feeds de noticias personalizadas; tutores educativos adaptativos.
Sistemas Autónomos	Vehículos autónomos; AGV (automated guided vehicle) de almacén; coordinación de semáforos; acoplamiento de naves espaciales.
Operaciones y Asignación de Recursos	Cloud job scheduling; dynamic pricing; control de redes eléctricas; ruteo de cadenas de suministro y gestión de inventarios.
Finanzas y Trading	Portfolio optimization; trading algorítmico; market making; detección secuencial de fraude.
Salud y Medicina	Dosificación óptima de drogas; planificación de radioterapia; clinical decision support; sistemas robóticos de rehabilitación.

Reinforcement learning “in a nutshell”

- En un modelo de Reinforcement Learning (RL), un agente interactúa en un entorno (environment).
- Dependiendo de la acción elegida por el agente, este cambia de estado y recibe una recompensa numérica.
- El objetivo del agente es elegir acciones que maximicen sus recompensas.
- Historicamente, RL se ha desarrollado en diferentes áreas, como Programación Dinámica, Procesos de decisión de Markov Decision (MDPs) y Sequential Decision Models.

Ejemplo *Grid world* (libro de Zhao)

- Celdas blancas están permitidas.
- Celdas naranjas están prohibidas/penalizadas.
- El objetivo del juego es llegar a la celda *Objetivo* (Target).

El tablero de celdas (+ reglas del juego) es conocido como **entorno** (environment)

Inicio		
		Prohibida
Prohibida		Objetivo

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

- El juego tendrá un **agente** que se desplaza por las casillas del entorno.
- El objetivo final es encontrar una “buena” secuencia de movimientos que le permita alcanzar la celda objetivo.
- El juego sería trivial si el agente conociera el mapa de antemano.
- El agente debe interactuar con el entorno para encontrar una buena “estrategia” mediante ensayo y error.




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Los **estados** describen las distintas “posiciones” que el agente puede tomar dentro del entorno.

El **espacio de estados** (state space) denota el conjunto de todos los estados del entorno.

$$\mathcal{S} = \{s_1, s_2, s_3, s_4, s_5, s_6, s_7, s_8, s_9\}$$

s_1	s_2	s_3
s_4	s_5	s_6
s_7	s_8	s_9


Actions

Las **acciones** son los posibles movimientos en cada estado.

El **espacio de acciones** (action space) denota el conjunto de todas las acciones.

$$\mathcal{A} = \{a_1, a_2, a_3, a_4, a_5\}$$

s_1	s_2	s_3
s_4	s_5	s_6
s_7	s_8	s_9



Obs: El espacio de acciones puede depender del estado (por ejemplo $\mathcal{A}(s_1) = \{a_2, a_3, a_5\}$)

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

State transition

Cuando el agente toma una acción, se puede mover de un estado a otro, esto se conoce como **transición de estado**. Por ejemplo si el agente está en el estado s_1 y elige la acción a_2 , el agente se mueve a s_2 (probablemente)

$$s_1 \xrightarrow{a_2} s_2$$

Matemáticamente, lo denotamos usando probabilidades condicionales

$$p(s_1|s_1, a_2) = 0$$

$$p(s_2|s_1, a_2) = 1$$

$$p(s_3|s_1, a_2) = 0$$

$$\vdots$$

$$p(s_9|s_1, a_2) = 0$$

Obs: Noten que, en el caso estocástico, elegir una acción puede conducir a diferentes estados.

s_1	s_2	s_3
s_4	s_5	s_6
s_7	s_8	s_9

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

State transition

Cuando el agente toma una acción, se puede mover de un estado a otro, esto se conoce como **transición de estado**. Por ejemplo si el agente está en el estado s_1 y elige la acción a_2 , el agente se mueve a s_2 (probablemente)

$$s_1 \xrightarrow{a_2} s_2$$

Matemáticamente, lo denotamos usando probabilidades condicionales

$$p(s_1|s_1, a_2) = 0.2$$

$$p(s_2|s_1, a_2) = 0.8$$

$$p(s_3|s_1, a_2) = 0$$

$$\vdots$$

$$p(s_9|s_1, a_2) = 0$$

Obs: Noten que, en el caso estocástico, elegir una acción puede conducir a diferentes estados.

s_1	s_2	s_3
s_4	s_5	s_6
s_7	s_8	s_9

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

El caso de transiciones determinísticas puede ser representado por tablas

	a_1 (arriba)	a_2 (derecha)	a_3 (abajo)	a_4 (izquierda)	a_5 (quieto)
s_1	s_1	s_2	s_4	s_1	s_1
s_2	s_2	s_3	s_5	s_1	s_2
s_3	s_3	s_3	s_6	s_2	s_3
s_4	s_1	s_5	s_7	s_4	s_4
s_5	s_2	s_6	s_8	s_4	s_5
s_6	s_3	s_6	s_9	s_5	s_6
s_7	s_4	s_8	s_7	s_7	s_7
s_8	s_5	s_9	s_8	s_7	s_8
s_9	s_6	s_9	s_9	s_8	s_9

Las **políticas** definen las acciones que el agente debe seguir en cada estado.




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Las **políticas** definen las acciones que el agente debe seguir en cada estado.

Matemáticamente, las políticas también se pueden describir con probabilidades condicionales:

$$\pi(a_1|s_1) = 0$$

$$\pi(a_2|s_1) = 1$$

$$\pi(a_3|s_1) = 0$$

$$\pi(a_4|s_1) = 0$$

$$\pi(a_5|s_1) = 0$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Las **políticas** definen las acciones que el agente debe seguir en cada estado.

Esto quiere decir que una política puede definir distintas probabilidades de tomar una acción, e.g.,

$$\pi(a_1|s_1) = 0$$

$$\pi(a_2|s_1) = 0.5$$

$$\pi(a_3|s_1) = 0.5$$

$$\pi(a_4|s_1) = 0$$

$$\pi(a_5|s_1) = 0$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Rewards

Después de realizar una acción en un estado, el agente obtiene una **recompensa** (r) como feedback del entorno.

$$r := r(s, a)$$

Este puede ser un valor positivo, negativo o cero.





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Después de realizar una acción en un estado, el agente obtiene una **recompensa** (r) como feedback del entorno.

$$r := r(s, a)$$

Este puede ser un valor positivo, negativo o cero.

Por ejemplo, las recompensas pueden definirse como:

- Si el agente trata de salir por un borde, $r = -1$.
- Si el agente entra a una celda prohibida, $r = -1$.
- Si el agente alcanza la celda target, $r = +1$.
- En otro caso, $r = 0$.





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Rewards

Después de realizar una acción en un estado, el agente obtiene una **recompensa** (r) como feedback del entorno.

$$r := r(s, a)$$

Este puede ser un valor positivo, negativo o cero.

Obs 1: **Recompensas** pueden ser vistas como una forma de “guiar” el comportamiento del agente.

Obs 2: En casos más generales, denotaremos las recompensas con probabilidades condicionales:

$$p(r|s, a)$$






Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.


Trajectories



Una **trayectoria** es una cadena de estado-acción-recompensa. Por ejemplo, dada la política de la izquierda, el agente se mueve a través de la trayectoria como sigue:

$$s_1 \xrightarrow[a_2]{r=0} s_2 \xrightarrow[a_3]{r=0} s_5 \xrightarrow[a_3]{r=0} s_8 \xrightarrow[a_2]{r=1} s_9$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.




El **retorno** de una trayectoria es la suma de todas las recompensas obtenidas durante la trayectoria:

$$\text{retorno} = 0 + 0 + 0 + 1 = 1$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

tareas episódicas y tareas continuas




La **tarea episódica** termina después de un número de acciones. La **tarea continua** continúa sin un límite de acciones.

$$\text{retorno episódico} = 0 + 0 + 0 + 1 = 1$$

$$\text{retorno continuo} = 0 + 0 + 0 + 1 + 1 + 1 + \dots = \infty$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

tareas episódicas y tareas continuas



Para evitar este problema, introducimos el concepto de **descuento**. Sea $\gamma \in (0, 1)$, entonces:

$$\text{retorno con descuento} = 0 + \gamma 0 + \gamma^2 0 + \gamma^3 1 + \gamma^4 1 + \gamma^5 1 + \dots = \gamma^3 \frac{1}{1 - \gamma}$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

En esta clase revisamos:

- Entorno (environment)
- Agente (agent)
- Estado (state)
- Acción (action)
- transición de estado (state transition)
- Recompensa (reward)
- Trayectorias y retornos

Próxima clase...


- Procesos de decisión de Markov (MDPs)

- Agente: Calefactor o termostato
- Estados: Temperatura de la habitación
- Acciones: Calefacción apagada, calefacción prendida (low, high)
- Recompensa: $-(T - T_{\text{comf}})^2 - \text{costo}(A)$



Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.

- Agente: ?
- Estados: ?
- Acciones: ?
- Recompensa: ?



The Great Flood

15 2025 · Sci-fi/Drama · 1h 48m

Overview

Cast

Reviews

Watch film



 The Guardian

The Great Flood review – Korean apocalypse movie swerves into...

Kim Byung-woo's chimeric but not unenjoyable sixth feature begins like a...

1 month ago