

Reinforcement Learning

Clase 02

Ignacio Brevis

`ignaciobrve@unisabana.edu.co`

Universidad de La Sabana

26 agosto 2026




En la clase anterior vimos:

- Entorno (environment)
- Agente (agent)
- Estado (state)
- Acción (action)
- Transición de estado (state transition)
- Políticas (policies)
- Recompensa (reward)
- Trayectorias y retornos (trajectories & returns)

Ejemplo *Grid world* (libro de Zhao)

- Celdas blancas están permitidas.
- Celdas naranjas están prohibidas/penalizadas.
- El objetivo del juego es llegar a la celda *Objetivo* (Target).

El tablero de celdas (+ reglas del juego) es conocido como **entorno** (environment)




- Agente: Calefactor o termostato
- Estados: Temperatura de la habitación
- Acciones: Calefacción apagada, calefacción prendida (low, high)
- Recompensa: $-(T - T_{\text{comf}})^2 - \text{costo}(A)$




Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.

- Agente:
- Estados:
- Acciones:
- Recompensa:




Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.

- Agente: conductor
- Estados:
- Acciones:
- Recompensa:




Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.

- Agente: conductor
- Estados: posición y velocidad $(x, \dot{x})$
- Acciones:
- Recompensa:




Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.

- Agente: conductor
- Estados: posición y velocidad $(x, \dot{x})$
- Acciones: reversa, neutro, acelerar $(-1, 0, 1)$
- Recompensa:



Coche situado de forma estocástica en el fondo de un valle sinusoidal sin potencia suficiente para llegar a la bandera de forma directa.


- Agente: conductor
- Estados: posición y velocidad $(x, \dot{x})$
- Acciones: reversa, neutro, acelerar $(-1, 0, 1)$
- Recompensa: -1 cada vez que no alcanza la bandera



“Ace addresses the challenges of physical real-time interaction through a new, high-speed perception system using event-based vision sensors, and a new control system based on **model-free reinforcement learning**” (Dürr et al., 2026, Abstract)

- 8 joints mounted on a mobile base
- 9 high-speed cameras to track the ball (200 FPS)
- Sensors to analyze spin hundreds of time per second

AI-powered robot beats elite table tennis players



REUTERS

Ace uses nine synchronized cameras and three vision systems to track a spinning ball


23 April 2026 · 1 Comments

www.nature.com/articles/s41586-026-10338-5 & www.bbc.co.uk/newsround/articles/c80mzpym1ygo

Episodic and continuing tasks

- **Episodic tasks:** La interacción entre el agente y el entorno se divide naturalmente en una secuencia de episodios independientes. Cada episodio termina en un **estado terminal** específico, seguido de un reinicio a un **estado inicial** estándar.
- **Continuing tasks:** La interacción no se divide de manera natural en episodios identificables, sino que continúa sin interrupción (sin un estado terminal); por ejemplo, una tarea de control de procesos continua (on-going).

Episodic and continuing tasks



return $= 0 + 0 + 0 + 1 = 1$ (episodic task)

return $= 0 + 0 + 0 + 1 + 1 + 1 + \dots$ (continuing task)

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Para evitar este problems, introducimos el concepto de **descuento**. Dado $\gamma \in (0, 1)$, tenemos:

$$\text{discounted return} = \sum_{i=0}^{\infty} \gamma^i r_{i+1} = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

Podemos tratar las tareas episódicas y continuas en un marco unificado al convertir las tareas episódicas en continuas. Para ello, debemos definir claramente qué sucede después de que el agente alcanza el estado terminal.

- Definimos estados terminales como estados especiales en el que el agente permanece para siempre.
- Definimos estados terminales como estados normales del que el agente puede salir y volver a entrar.

Un **Proceso de decisión de Markov** o Markov decision process (MDP) es un proceso estocástico discreto compuesto por:

- Conjuntos:

- • Espacio de estados $\mathcal{S}$ (state space)
- • Espacio de acciones $\mathcal{A}(s)$ (action space), con $s \in \mathcal{S}$
- • Conjunto de recompensas $\mathcal{R}(s, a)$ (reward set), con $s \in \mathcal{S}$ y $a \in \mathcal{A}(s)$

- Modelo o dinámica

- • Probabilidad de transición de estado: $p(s'|s, a)$
- • Probabilidad de recompensa: $p(r|s, a)$



$$p(\underline{s'}|\underline{s}, \underline{a})$$

- Política

- Probabilidad de acción a : $\pi(a|s)$

- Propiedad Markoviana

- $p(s_{t+1}|s_t, a_t, \underbrace{s_{t-1}, a_{t-1}, \dots, s_0, a_0}) = p(s_{t+1}|s_t, a_t)$
- $p(r_{t+1}|s_t, a_t, \underbrace{s_{t-1}, a_{t-1}, \dots, s_0, a_0}) = p(r_{t+1}|\underbrace{s_t, a_t})$



Obs: Una vez que fijamos la política en el MDP, se convierte en un proceso de Markov.

Markov decision processes

Obs: Notemos que, dado $s \in \mathcal{S}$ y $a \in \mathcal{A}(s)$,

$$\sum_{a \in \mathcal{A}(s)} \pi(a|s) = 1,$$

$$\sum_{s' \in \mathcal{S}} p(s'|s, a) = 1,$$

y

$$\sum_{r \in \mathcal{R}(s, a)} p(r|s, a) = 1,$$

$$\begin{aligned} \pi(a_1|s) &= 0,5 \\ \pi(a_2|s) &= 0,3 \\ \pi(a_3|s) &= 0 \\ \pi(a_4|s) &= 0,2 \end{aligned}$$

$$p(s_9|s_9, a) = 1$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Retorno

Comparemos las siguientes políticas:



(Como las políticas solo difieren en s_1 , estudiaremos el retorno para ese estado)

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Ejercicio: Límite de sumatoria

Mostrar que si $0 < \gamma < 1$, entonces:

$$\gamma + \gamma^2 + \gamma^3 + \dots := \lim_{N \rightarrow \infty} \sum_{k=1}^N \gamma^k = \frac{\gamma}{1-\gamma}$$

$$\lim_{N \rightarrow \infty} \frac{(\gamma + \gamma^2 + \dots + \gamma^N)(1-\gamma)}{(1-\gamma)}$$

$$\lim_{N \rightarrow \infty} \frac{(\gamma + \cancel{\gamma^2} + \dots + \cancel{\gamma^N}) - (\cancel{\gamma^2} + \cancel{\gamma^3} + \dots + \cancel{\gamma^N} + \gamma^{N+1})}{1-\gamma}$$

$$\lim_{N \rightarrow \infty} \frac{\gamma - \gamma^{N+1}}{1-\gamma} = \boxed{\frac{\gamma}{1-\gamma}}$$

Markov decision process: Retorno

Ejemplo: politica 1

retorno =

$$\begin{aligned} r_1(s_1) &= 0 + \gamma \cdot 1 + \gamma^2 \cdot 1 + \gamma^3 \cdot 1 + \dots \\ &= \gamma + \gamma^2 + \gamma^3 + \dots \\ &= \frac{\gamma}{1-\gamma} \end{aligned}$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Retorno

$$\text{política 1} \quad \frac{\gamma}{1-\gamma} > \frac{\gamma}{1-\gamma} - 1 \quad \text{política 2}$$

Ejemplo: política 2

retorno =

$$\begin{aligned} r_2(s_1) &= -1 + 1 \cdot \gamma + 1 \gamma^2 + \dots \\ &= -1 + \underbrace{\gamma + \gamma^2 + \dots} \\ &= \frac{\gamma}{1-\gamma} - 1 \end{aligned}$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Ejemplo: politica 3
retorno promedio =

$$\begin{aligned} r_3(s_1) &= 0.5 \frac{\gamma}{1-\gamma} + 0.5 \left(\frac{\gamma}{1-\gamma} - 1 \right) \\ &= \frac{\gamma}{1-\gamma} - 0.5 \end{aligned}$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Retorno



retorno(política 1) > retorno(política 3) > retorno(política 2)

$$\frac{\gamma}{1-\gamma}$$

$$\frac{\gamma}{1-\gamma} - 0,5$$

$$\frac{\gamma}{1-\gamma} - 1$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Calcular políticas

Consideremos el siguiente ejemplo. Calculemos la probabilidad de transición de s_i a s_j (bajo la política π):

$p_{\pi}(s_j s_i)$	s_1	s_2	s_3	s_4
s_1	0	1	0	0
s_2	0	0	1	0
s_3	0	0	0	1
s_4	1	0	0	0

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Calcular políticas

$$V_1 = r_1 + \gamma V_2 \quad V_3 = r_3 + \gamma V_4$$

$$V_2 = r_2 + \gamma V_3 \quad V_4 = r_4 + \gamma V_1$$

Denotemos v_i al retorno obtenido al comenzar en el estado s_i

$$\begin{cases} v_1 = \underline{r_1} + \gamma \underline{r_2} + \gamma^2 \underline{r_3} + \dots \\ v_2 = \underline{r_2} + \gamma \underline{r_3} + \gamma^2 \underline{r_4} + \dots \\ v_3 = r_3 + \gamma r_4 + \gamma^2 r_1 + \dots \\ v_4 = r_4 + \gamma r_1 + \gamma^2 r_2 + \dots \end{cases}$$

$$\begin{aligned} V_1 &= r_1 + \gamma r_2 + \gamma^2 r_3 + \gamma^3 r_4 + \dots \\ &= r_1 + \gamma \underbrace{(r_2 + \gamma r_3 + \gamma^2 r_4 + \dots)}_{V_2} \end{aligned}$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Calcular políticas

systemas lineales

$$\begin{cases} v_1 = r_1 + \gamma v_2 & v_3 = r_3 + \gamma v_4 \\ v_2 = r_2 + \gamma v_3 & v_4 = r_4 + \gamma v_1 \end{cases}$$

Denotemos v_i al retorno obtenido al comenzar en el estado s_i


$$\begin{cases} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} + \gamma \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} \end{cases}$$

$$\vec{v} = \vec{r} + \gamma P \vec{v}$$

$$\vec{v} - \gamma P \vec{v} = \vec{r} \Rightarrow \underbrace{(I - \gamma P)}_A \vec{v} = \vec{r} \quad \vec{x} = \vec{b}$$

algebra lineal

$$A \vec{x} = \vec{b} \Rightarrow \vec{x} = A^{-1} \vec{b}$$



$$\vec{v}, \underline{v}, v = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{pmatrix}$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Markov decision process: Calcular políticas

La ecuación descrita abajo es conocida como la **ecuación de Bellman**

$$\rightarrow \boxed{v = r + \gamma P v}$$

↓
político

Obs: Podemos calcular $v = (I - \gamma P)^{-1} r$

$$v = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{pmatrix}$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Anteriormente mencionamos que los retornos nos ayudan a evaluar políticas. Sin embargo, no son aplicables en sistemas estocásticos, ya que los retornos pueden variar para un mismo estado inicial. Es por esto que utilizaremos el concepto de **función de valor** (value function o state-value function).

Consideremos una secuencia de pasos $t = 0, 1, 2, \dots$. En el paso t , el agente está en el estado S_t . Siguiendo la política π , toma la acción A_t . El siguiente estado es S_{t+1} e inmediatamente obtiene la recompensa R_{t+1} , i.e.,

$$\underline{S_t} \xrightarrow{\underline{A_t}} \underline{S_{t+1}}, \underline{R_{t+1}}.$$

Obs: Notemos que S_t , S_{t+1} , A_t y R_{t+1} son variables aleatorias.

Obs: R_{t+1} y R_t se utilizan en la literatura para denotar la recompensa obtenida por la acción A_t . Aquí seguiremos la notación de los libros Sutton y Zhao (R_{t+1})

State value

Luego podemos definir la trayectoria estado-acción-recompensa:

$$* \quad \underline{S_t} \xrightarrow{A_t} \underline{S_{t+1}}, \underline{R_{t+1}} \xrightarrow{A_{t+1}} \underline{S_{t+2}}, \underline{R_{t+2}} \xrightarrow{A_{t+2}} \underline{S_{t+3}}, \underline{R_{t+3}} \dots$$

y el retorno con descuento de la trayectoria:

$$\underline{G_t} := \sum_{k=0} \gamma^k R_{t+k+1} = \underline{R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots}$$

con γ el ratio de descuento.

Obs: G_t es una variable aleatoria!

$$v \approx \mathbb{E}(G_t | S_t = s) = v_{\pi}(s)$$

State-value function

Dada una política π y $s \in \mathcal{S}$. La **función de valor** se define como valor esperado de G_t

$$\underline{v_{\pi}(s)} = \underline{\mathbb{E}[G_t | S_t = s]} \leftarrow$$

$$\rightarrow v_i = r_i + \gamma v_j + \gamma^2 v_k + \dots$$

$$\underline{G_i} = R_1 + \gamma R_2 + \gamma^2 R_3 + \dots$$

State-value function

Dada una política π y $s \in \mathcal{S}$. La **función de valor** se define como valor esperado de G_t

$$v_{\pi}(s) := \mathbb{E}[G_t | S_t = s]$$

- $v_{\pi}(s)$ depende de s .
- $v_{\pi}(s)$ depende de la política π .
- $v_{\pi}(s)$ no depende de t .

Obs: Cuando la política y la dinámica (transición y recompensa) son determinísticas, un estado inicial siempre generará la misma trayectoria.

Obs: Si la política y la dinámica son estocásticas, un estado inicial puede dar lugar a diferentes trayectorias. Las recompensas de diferentes trayectorias pueden ser distintas, y la función de valor será el valor esperado de dichas recompensas.

Recuerdo de probabilidades

- Notación: $p(X = x)$ = $p(x)$

- ✖ • Probabilidad conjunta: $\sum_y p(x, y) = p(x)$

- Probabilidad condicional: $p(x, a)$ = $p(x|a)p(a)$ ✖

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$\Rightarrow \underline{p(x)} = \sum_a \underline{p(x, a)} = \sum_a \underline{p(x|a)p(a)}$$

- ✖ • Ley de la probabilidad total: $p(x|a)$ = $\sum_y$ $p(x, y|a)$

- ✖ • Valor esperado: $\mathbb{E}[X] = \sum_x p(x)x = \sum_x p(X=x)x$

Recuerdo de probabilidades

$$\begin{array}{|l} \sum_y p(x, y) = p(x) \\ p(x, a) = p(x|a)p(a) \\ p(x) = \sum_a p(x|a)p(a) \\ p(x|a) = \sum_y p(x, y|a) \end{array}$$

✱ • Valor esperado: $\mathbb{E}[X] = \sum_x p(x)x$

✱ • Linealidad del valor esperado: $\mathbb{E}[X + \alpha Y] = \mathbb{E}[X] + \alpha \mathbb{E}[Y]$

• Esperanza condicional: $\mathbb{E}[X|A = a] = \sum_x p(x|a)x$ ←

• Ley de esperanzas totales o iteradas:

$$\mathbb{E}[X] = \sum_a \mathbb{E}[X|A = a]p(a)$$

✱ $\mathbb{E}[X|A = a] = \sum_b \mathbb{E}[X|A = a, B = b]p(b|a)$

Ejercicio: probabilidad condicional

✗ Probar que $\mathbb{E}[X] = \sum_a \mathbb{E}[X|A = a]p(a)$