

Reinforcement Learning

Clase 03

Ignacio Brevis

`ignaciobrve@unisabana.edu.co`



Universidad de La Sabana

02 septiembre 2026




Un **Proceso de decisión de Markov** o Markov decision process (MDP) es un proceso estocástico discreto compuesto por:

- Conjuntos:
 - Espacio de estados $\mathcal{S}$ (state space)
 - Espacio de acciones $\mathcal{A}(s)$ (action space), con $s \in \mathcal{S}$
 - Conjunto de recompensas $\mathcal{R}(s, a)$ (reward set), con $s \in \mathcal{S}$ y $a \in \mathcal{A}(s)$
- Modelo o dinámica
 - Probabilidad de transición de estado: $p(s'|s, a)$
 - Probabilidad de recompensa: $p(r|s, a)$
- Política
 - Probabilidad de acción a : $\pi(a|s)$
- Propiedad Markoviana
 - $p(s_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = p(s_{t+1}|s_t, a_t)$
 - $p(r_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = p(r_{t+1}|s_t, a_t)$



Obs: Una vez que fijamos la política en el MDP, se convierte en un proceso de Markov.

Repaso: Retorno



retorno(política 1) > retorno(política 3) > retorno(política 2)

$$\Rightarrow \underline{r(s_1) = \frac{\gamma}{1-\gamma}} \quad \underline{r(s_1) = \frac{\gamma}{1-\gamma} - 0.5} \quad \underline{r(s_1) = \frac{\gamma}{1-\gamma} - 1}$$

Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Repaso: Bellman equation

v "retorno"

La ecuación descrita abajo es conocida como la **ecuación de Bellman**

v vector
 P "matriz"

$$v = r + \gamma P v$$

Obs: Podemos calcular

$$v = (I - \gamma P)^{-1} r$$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

- Conjunta:


$$p(x) = \sum_y p(x, y)$$

- Condicional: $p(x, a) = p(x|a)p(a)$ 

$$p(x) = \sum_a p(x|a)p(a)$$

- Probabilidad total:


$$p(x|a) = \sum_y p(x, y|a)$$

- Valor esperado: $\mathbb{E}[X] = \sum p(x)x$

$$\mathbb{E}[X + \alpha Y] = \mathbb{E}[X] + \alpha \mathbb{E}[Y]$$

- Esperanza condicional:


$$\mathbb{E}[X|A = a] = \sum_x p(x|a)x$$

- Ley de esperanzas totales o iteradas:


$$\mathbb{E}[X] = \sum_a \mathbb{E}[X|A = a]p(a)$$


$$\mathbb{E}[X|A = a] = \sum_b \mathbb{E}[X|A = a, B = b]p(b|a)$$

Ejercicio: probabilidad condicional

Probar que $\mathbb{E}[X] = \sum_a \mathbb{E}[X|A=a]p(a)$

$$\begin{aligned}\sum_a \mathbb{E}(X|A=a)p(a) &= \sum_a \sum_x x p(x|a) p(a) \\ &= \sum_x x \sum_a \underbrace{p(x|a)p(a)}_{p(x,a)} \\ &= \sum_x x \underbrace{\left(\sum_a p(x,a) \right)}_{p(x)} = \sum_x x p(x) = \underline{\underline{\mathbb{E}(X)}}\end{aligned}$$

Repaso: Función de valor

Los retornos nos ayudan a evaluar políticas. Sin embargo, no son aplicables a sistemas estocásticos, ya que los retornos pueden variar para un mismo estado inicial.

Consideremos una secuencia de pasos $t = 0, 1, 2, \dots$. En el paso t , el agente está en el estado S_t . Siguiendo la política π , toma la acción A_t . El siguiente estado es S_{t+1} e inmediatamente obtiene la recompensa R_{t+1} . Luego podemos definir la trayectoria estado-acción-recompensa:

$$\star \quad \underline{S_t} \xrightarrow{\underline{A_t}} \underline{S_{t+1}}, \underline{R_{t+1}} \xrightarrow{\underline{A_{t+1}}} \underline{S_{t+2}}, \underline{R_{t+2}} \xrightarrow{A_{t+2}} S_{t+3}, R_{t+3} \dots$$

y el retorno con descuento de la trayectoria:

$$G_{t+1} = R_{t+2} + \gamma R_{t+3} + \dots$$

$$\underline{G_t} := \sum_{k=0} \gamma^k R_{t+k+1} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \leftarrow$$

con γ el ratio de descuento.

$$\rightarrow \boxed{G_t = R_{t+1} + \gamma (R_{t+2} + \gamma R_{t+3} + \dots)} \\ \rightarrow \boxed{G_t = R_{t+1} + \gamma G_{t+1}}$$

[Obs: Notemos que $S_t, S_{t+1}, A_t, R_{t+1}$ y G_t son variables aleatorias!]

Repaso: Función de valor

Para lidiar con la estocasticidad de los sistemas, definimos la **función de valor** (value function o state-value function).

State-value function

Dada una política π y $s \in \mathcal{S}$. La **función de valor** se define como valor esperado de G_t

$$\star v_{\pi}(s) := \mathbb{E}[G_t | S_t = s]$$

- $\star \bullet v_{\pi}(s)$ depende de s .
- $\star \bullet v_{\pi}(s)$ depende de la política π .
- $\star \bullet v_{\pi}(s)$ no depende de t .

Obs: Cuando la política y la dinámica (transición y recompensa) son determinísticas, un estado inicial siempre generará la misma trayectoria.

Obs: Si la política y la dinámica son estocásticas, un estado inicial puede dar lugar a diferentes trayectorias. Las recompensas de diferentes trayectorias pueden ser distintas, y la función de valor será el valor esperado de dichas recompensas.

Bellman equation

En pocas palabras, la ecuación de Bellman es un sistema de ecuaciones lineales que describe la relación de la función de valor entre los estados.

$$\rightarrow v_{\pi}(s) = \mathbb{E}[G_t | S_t = s]$$

$$= \mathbb{E}(R_{t+1} + \gamma G_{t+1} | S_t = s)$$

$$= \underbrace{\mathbb{E}(R_{t+1} | S_t = s)}_{\textcircled{1}} + \gamma \underbrace{\mathbb{E}(G_{t+1} | S_t = s)}_{\textcircled{2}}$$

recomp.
inmediatas

recomp.
futuras.

Bellman equation

$$\begin{aligned}\textcircled{1} \mathbb{E}[R_{t+1} | S_t = s] &= \sum_a \mathbb{E}(R_{t+1} | S_t = s, A_t = a) \underbrace{p(a | s)}_{\pi(a | s)} \\ &= \sum_a \mathbb{E}(R_{t+1} | S_t = s, A_t = a) \pi(a | s) \\ &= \sum_a \sum_r \overbrace{p(r | s, a) r} \pi(a | s) \\ &= \boxed{\sum_a \pi(a | s) \sum_r p(r | s, a) r}\end{aligned}$$

Bellman equation

$$\begin{aligned}\mathbb{E}[G_{t+1} | S_t = s] &= \sum_{s'} \mathbb{E}(G_{t+1} | S_t = s, S_{t+1} = s') p(s' | s) \\&= \sum_{s'} \underbrace{\mathbb{E}(G_{t+1} | S_{t+1} = s')}_{V_\pi(s')} p(s' | s) \\&= \sum_{s'} V_\pi(s') p(s' | s) \\&= \sum_{s'} V_\pi(s') \sum_a p(s' | s, a) \pi(a | s) \\&= \boxed{\sum_a \pi(a | s) \sum_{s'} V_\pi(s') p(s' | s, a)}\end{aligned}$$

continúa...

Bellman equation

$$\begin{aligned} v_{\pi}(s) &= \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s'), \\ &= \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s') \right], \quad \forall s \in \mathcal{S} \end{aligned}$$

es la **ecuación de Bellman**.

para todo

- Notemos que $v_{\pi}(s)$ y $v_{\pi}(s')$ son las incógnitas.
- Para resolver la ecuación, tenemos que generar un sistema con tantas ecuaciones como elementos hay en $\mathcal{S}$.
- ✱ • $\pi := \pi(a|s)$ es una política dada, y la función de valor nos permite evaluarla. Resolver la ecuación de Bellman nos permite realizar dicha evaluación.
- $p(r|s, a)$ y $p(s'|s, a)$ nos proporcionan la dinámica del sistema.

Bellman equation

Otras expresiones equivalentes: Usando la ley de probabilidades totales,

$$\underline{p(s'|s, a) = \sum_r p(s', r|s, a)} \quad \text{y} \quad \underline{p(r|s, a) = \sum_{s'} p(s', r|s, a)},$$

Tenemos que:

$$\star \quad v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r|s, a) \underline{[r + \gamma v_{\pi}(s')]}, \quad \forall s \in \mathcal{S}$$

Además, si r depende únicamente del estado s' , i.e., $r := r(s')$, tenemos que

$$p(r|s, a) = p(s'|s, a) \text{ y}$$

$$\star \quad v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{s' \in \mathcal{S}} p(s'|s, a) [r(s') + \gamma v_{\pi}(s')], \quad \forall s \in \mathcal{S}$$

Bellman equation: Ejemplo 1

Calcular el sistema de Bellman (tomando $\gamma = 0.9$)

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a) v_{\pi}(s') \right]$$

$$v_{\pi}(s_1) = \underbrace{\pi(\downarrow|s_1)}_1 \left[\sum_r p(r|s_1, \downarrow) r + \gamma \sum_{s'} p(s'|s_1, \downarrow) v_{\pi}(s') \right]$$

$$= \sum_r p(r|s_1, \downarrow) r + \gamma \sum_{s'} p(s'|s_1, \downarrow) v_{\pi}(s')$$

$$= \underbrace{p(r=0|s_1, \downarrow)}_1 \underbrace{(r=0)}_{=0} + \gamma \underbrace{p(s_3|s_1, \downarrow)}_1 v_{\pi}(s_3)$$

$$v_{\pi}(s_1) = \gamma v_{\pi}(s_3)$$

$$v_{\pi}(s_2) = 1 + \gamma v_{\pi}(s_4)$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 1

Calcular el sistema de Bellman (tomando $\gamma = 0.9$) (continúa...)

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s') \right]$$

$$\begin{cases} v_{\pi}(s_1) = \gamma v_{\pi}(s_3) \\ v_{\pi}(s_2) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_3) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_4) = 1 + \gamma v_{\pi}(s_4) \end{cases}$$

$$\begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ v_{\pi}(s_3) \\ v_{\pi}(s_4) \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ v_{\pi}(s_3) \\ v_{\pi}(s_4) \end{bmatrix}$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 1

Calcular el sistema de Bellman (tomando $\gamma = 0.9$) (continúa...)

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s') \right]$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 2

Calcular el sistema de Bellman (tomando $\gamma = 0.9$)

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s') \right]$$

$$\begin{aligned} v_{\pi}(s_1) &= \sum_a \pi(a|s_1) (\%) \\ &= \underbrace{\pi(\rightarrow|s_1)}_{a=\rightarrow} (\%) + \underbrace{\pi(\downarrow|s_1)}_{a=\downarrow} (\%) \\ &= 0,5(-1 + \gamma v_{\pi}(s_2)) + 0,5(\gamma v_{\pi}(s_3)) \\ &= -0,5 + \frac{\gamma}{2} v_{\pi}(s_2) + \frac{\gamma}{2} v_{\pi}(s_3) \end{aligned}$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 2

Calcular el sistema de Bellman (tomando $\gamma = 0.9$) (continúa...)

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\sum_{r \in \mathcal{R}} p(r|s, a)r + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a)v_{\pi}(s') \right]$$

$$\begin{cases} v_{\pi}(s_1) = -0.5 + \frac{\gamma}{2} v_{\pi}(s_2) + \frac{\gamma}{2} v_{\pi}(s_3) \\ v_{\pi}(s_2) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_3) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_4) = 1 + \gamma v_{\pi}(s_4) \end{cases}$$

$$\begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -0.5 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma \begin{bmatrix} 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ v_{\pi}(s_3) \\ v_{\pi}(s_4) \end{bmatrix}$$





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Matrix form

La ecuación de Bellman puede ser reescrita de una forma matricial, para esto primero definamos

$$\underline{r_\pi(s)} := \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{r \in \mathcal{R}} p(r|s, a)r, \quad \text{y} \quad \underline{p_\pi(s'|s)} := \sum_{a \in \mathcal{A}} \pi(a|s)p(s'|s, a)$$

- $r_\pi(s)$ denota el valor esperado de las recompensas inmediatas bajo la política π .
- $p_\pi(s'|s)$ representa la probabilidad de transición de s a s' bajo la política π .

Sea $n = |\mathcal{S}|$ el número de estados. Para cada estado s_i con $i = 1, \dots, n$, podemos definir la ecuación de Bellman de la forma:

$$\star \quad \boxed{\underline{v_\pi(s_i)} = \underline{r_\pi(s_i)} + \gamma \sum_{s_j \in \mathcal{S}} \underline{p_\pi(s_j|s_i)} \underline{v_\pi(s_j)}}$$

Bellman equation: Matrix form


$$v_{\pi}(s_i) = r_{\pi}(s_i) + \gamma \sum_{s_j \in \mathcal{S}} p_{\pi}(s_j | s_i) v_{\pi}(s_j)$$

Reescribiendo...

$$\underline{v_{\pi}} = \begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ \vdots \\ v_{\pi}(s_n) \end{bmatrix}, \quad \underline{r_{\pi}} = \begin{bmatrix} r_{\pi}(s_1) \\ r_{\pi}(s_2) \\ \vdots \\ r_{\pi}(s_n) \end{bmatrix}, \quad \underline{P_{\pi}} = \begin{bmatrix} p_{\pi}(\underline{s_1} | \underline{s_1}) & p_{\pi}(\underline{s_2} | \underline{s_1}) & \cdots & p_{\pi}(s_n | s_1) \\ p_{\pi}(s_1 | \underline{s_2}) & p_{\pi}(\underline{s_2} | \underline{s_2}) & \cdots & p_{\pi}(s_n | s_2) \\ \vdots & \vdots & \ddots & \vdots \\ p_{\pi}(s_1 | s_n) & p_{\pi}(s_2 | s_n) & \cdots & p_{\pi}(s_n | s_n) \end{bmatrix}$$

con $v_{\pi} \in \mathbb{R}^n$, $r_{\pi} \in \mathbb{R}^n$ y $P_{\pi} \in \mathbb{R}^{n \times n}$.

La ecuación de Bellman se puede escribir de la forma matricial:


$$\underline{v_{\pi}} = \underline{r_{\pi}} + \gamma \underline{P_{\pi}} \underline{v_{\pi}}$$

Bellman equation: Matrix form

Retomando el ejemplo anterior,

$$v_{\pi}(s_i) = r_{\pi}(s_i) + \gamma \sum_{s_j \in \mathcal{S}} p_{\pi}(s_j | s_i) v_{\pi}(s_j)$$

$$\begin{bmatrix} \underline{v_{\pi}(s_1)} \\ \underline{v_{\pi}(s_2)} \\ \underline{v_{\pi}(s_3)} \\ \underline{v_{\pi}(s_4)} \end{bmatrix} = \begin{bmatrix} 0.5(0) + 0.5(-1) \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma \begin{bmatrix} 0 & \underline{0.5} & \underline{0.5} & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ v_{\pi}(s_3) \\ v_{\pi}(s_4) \end{bmatrix}.$$

$\underline{v_{\pi}}$ γ P_{π} v_{π}





Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Solución cerrada

Como $v_\pi = r_\pi + \gamma P_\pi v_\pi$ es un sistema lineal, puede ser “fácilmente” resuelto al invertir $(I - \gamma P_\pi)$

$$(I - \gamma P_\pi)^{-1}$$

$$v_\pi = (I - \gamma P_\pi)^{-1} r_\pi$$

Obs: En la práctica, calcular la **inversa** de una matriz de $n \times n$ puede ser muy **costoso**!

Obs: El número de operaciones necesarias para calcular la inversa de una matriz de $n \times n$, crece proporcionalmente como n^3 .

Obs: En la práctica, no calculamos la inversa explícitamente, sino que podemos usar funciones como `numpy.linalg.solve` para resolver el sistema lineal.

Bellman equation: Solución iterativa

Otra alternativa es usar métodos iterativos. Por ejemplo, la ecuación de Bellman

$$v_{\pi} = r_{\pi} + \gamma P_{\pi} v_{\pi}$$

Se puede resolver de forma iterativa:

$$v_0 = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

$$\boxed{v_{k+1} = r_{\pi} + \gamma P_{\pi} v_k, \quad k = 0, 1, 2, \dots}$$

$v_1, v_2, \dots, v_k \rightarrow v_{\pi}$

$P_{\pi} \leftarrow RL$
no es conocido

Obs: Este método, no nos entrega la solución exacta de v_{π} , pero nos proporciona una aproximación que cada vez “se acerca más” a v_{π} .

Bellman equation: Ejemplo 1

Calcular la función de valor v_π ,

$$(I - \gamma P_\pi)v_\pi = r_\pi$$

recordar que:

- $[P_\pi]_{ij} := p_\pi(s_j|s_i) = \sum_a \pi(a|s_i)p(s_j|s_i, a)$
- $r_\pi(s_i) = \sum_a \pi(a|s_i) \sum_r p(r|s_i, a)$
- Entrar a una celda blanca, $r = 0$.
- Entrar a una celda naranja, $r = -1$.
- Alcanzar la celda azul, $r = +1$.




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 1

(continúa...)

- $[P_\pi]_{ij} := p_\pi(s_j|s_i) = \sum_a \pi(a|s_i) p(s_j|s_i, a)$
- $r_\pi(s_i) = \sum_a \pi(a|s_i) \sum_r p(r|s_i, a)$

Handwritten sequence: $\sqrt{0 \ 1 \ 0 \ \dots}$




Image adapted from Zhao, Mathematical Foundations of Reinforcement Learning.

Bellman equation: Ejemplo 2

Calcular la función de valor v_π para el siguiente juego:

- $\mathcal{A} = \{\uparrow, \rightarrow, \downarrow, \leftarrow\}$
- En cada celda, cada una de las 4 acciones es igualmente probable ($\pi(a|s_i) = 1/4$, con $a \in \mathcal{A}$).
- Acciones que lleven al agente fuera del entorno, dejan al agente en la misma celda y generan una recompensa de $r = -1$.
- Desde s_2 , todas las acciones tienen una recompensa de +10 y llevan al agente a s_{22} .
- Desde s_4 , todas las acciones tienen una recompensa de +5 y llevan al agente a s_{14} .
- Todas las otras acciones tienen una recompensa $r = 0$.




Image adapted from Sutton and Barto, Reinforcement Learning: An Introduction.